

Projeto Final – Mineração de Dados – DSM - Prof. Adriana Talhari

Nome: Mauro do Prado Santos

Projeto – Parte 1: Regras de Associação (Apriori e FP-Growth)

Objetivo: Aplicar algoritmos de regras de associação para identificar padrões de consumo em uma plataforma de streaming, interpretar os resultados obtidos e relacioná-los ao processo de tomada de decisão.

Base de Dados: BaseStreamingNominalApenasTrue.arff

Codificar em Python. Evidenciar resposta neste documento. Enviar código e este documento até o prazo de entrega.

1. Geração das regras (Pontuação: 15)

Utilizar os algoritmos:

- Apriori
- FP-Growth

Considerar:

- suporte mínimo = 20%
- confiança mínima = 80%

Quais foram as 14 regras mais fortes encontradas nos algoritmos? Para cada regra apresentar: antecedente, consequente, suporte e confiança.

Apriori - 14 regras mais fortes

#	Antecedente	Consequente	Suporte	Confiança
1	Acao, Aventura	FiccaoCientifica	29,00%	100,00%
2	Acao, FiccaoCientifica	Aventura	29,00%	93,55%
3	Aventura	FiccaoCientifica	32,00%	91,43%
4	Acao	FiccaoCientifica	31,00%	91,18%
5	Aventura, FiccaoCientifica	Acao	29,00%	90,62%
6	Comedia	Romance	35,00%	89,74%

7	Romance	Comedia	35,00%	85,37%
8	Acao	Aventura	29,00%	85,29%
9	Acao	Aventura, FiccaoCientifica	29,00%	85,29%
10	FiccaoCientifica	Aventura	32,00%	84,21%
11	Aventura	Acao	29,00%	82,86%
12	Aventura	Acao, FiccaoCientifica	29,00%	82,86%
13	Terror	Suspense	27,00%	81,82%
14	FiccaoCientifica	Acao	31,00%	81,58%

FP-Growth - 14 regras mais fortes

#	Antecedente	Consequente	Suporte	Confiança
1	Acao, Aventura	FiccaoCientifica	29,00%	100,00%
2	Acao, FiccaoCientifica	Aventura	29,00%	93,55%
3	Aventura	FiccaoCientifica	32,00%	91,43%
4	Acao	FiccaoCientifica	31,00%	91,18%
5	Aventura, FiccaoCientifica	Acao	29,00%	90,62%
6	Comedia	Romance	35,00%	89,74%
7	Romance	Comedia	35,00%	85,37%
8	Acao	Aventura	29,00%	85,29%
9	Acao	Aventura, FiccaoCientifica	29,00%	85,29%
10	FiccaoCientifica	Aventura	32,00%	84,21%
11	Aventura	Acao	29,00%	82,86%
12	Aventura	Acao, FiccaoCientifica	29,00%	82,86%
13	Terror	Suspense	27,00%	81,82%
14	FiccaoCientifica	Acao	31,00%	81,58%

2. Demonstração matemática do cálculo do suporte e da confiança das 3 regras com maior confiança (Pontuação: 15)

Requisitos:

a) Quantidade de ocorrências dos antecedentes

- b) Quantidade de ocorrências da regra completa
 - c) Cálculo do suporte da regra
 - d) Cálculo da confiança da regra
- Exemplo de Regra: Acao → FiccaoCientifica

Regra 1: Acao, Aventura -> FiccaoCientifica

- Quantidade total de registros: 100
- a) Quantidade de ocorrências dos antecedentes: 29
- b) Quantidade de ocorrências da regra completa: 29
- c) Suporte = ocorrências da regra completa / total = $29 / 100 = 29,00\%$
- d) Confiança = ocorrências da regra completa / ocorrências dos antecedentes = $29 / 29 = 100,00\%$

Regra 2: Acao, FiccaoCientifica -> Aventura

- Quantidade total de registros: 100
- a) Quantidade de ocorrências dos antecedentes: 31
- b) Quantidade de ocorrências da regra completa: 29
- c) Suporte = ocorrências da regra completa / total = $29 / 100 = 29,00\%$
- d) Confiança = ocorrências da regra completa / ocorrências dos antecedentes = $29 / 31 = 93,55\%$

Regra 3: Aventura -> FiccaoCientifica

- Quantidade total de registros: 100
- a) Quantidade de ocorrências dos antecedentes: 35
- b) Quantidade de ocorrências da regra completa: 32
- c) Suporte = ocorrências da regra completa / total = $32 / 100 = 32,00\%$
- d) Confiança = ocorrências da regra completa / ocorrências dos antecedentes = $32 / 35 = 91,43\%$

3. Interpretação de algumas das regras (sugestão 3 regras) e explicação de algumas ações que poderiam ser tomadas com base nos padrões encontrados. (Pontuação: 10)

- **Acao, Aventura -> FiccaoCientifica:** Todos os usuários/registros que indicaram Ação e Aventura também indicaram Ficção Científica. A plataforma pode criar trilhas, coleções e recomendações automáticas misturando esses três gêneros.
- **Comedia -> Romance:** A presença de Comédia aparece fortemente associada a Romance. Uma ação possível é recomendar comédias românticas ou destacar títulos de Romance para usuários que assistem Comédia.
- **Terror -> Suspense:** Terror tem forte relação com Suspense. Isso sugere campanhas conjuntas, categorias de catálogo combinadas e recomendações cruzadas entre esses gêneros.

Conclusão: As regras mais fortes mostram afinidade entre gêneros de ação/aventura/ficção científica, entre comédia/romance e entre terror/suspense. Esses padrões ajudam a melhorar recomendações, organizar o catálogo e planejar campanhas direcionadas.

Projeto – Parte 2: Pré-processamento, Regressão, Classificação e Agrupamento

Objetivo: Aplicar algoritmos de Regressão Linear para estimar os valores das casas. Comparar alguns algoritmos de Classificação. Realizar a tarefa de agrupamento de dados.

Base de Dados: <https://www.kaggle.com/datasets/yasserh/housing-prices-dataset>

Codificar em Python. Evidenciar resposta neste documento. Enviar código e este documento até o prazo de entrega.

4. Pré-processamento dos Dados (Pontuação: 5)

Instruções:

- Verificar se existe dados ausentes. Se sim, em quais atributos? Se ausente, preencher com média ou moda do atributo.
- Realizar as seguintes transformações nos dados:
Atributos categóricos preenchidos com “yes” ou “no” viram numéricos (yes = 1, no = 0).
Atributo “furnishingstatus” vira numérico (furnished = 2, semi-furnished = 1, unfurnished = 0).

Resultado:

Não foram encontrados dados ausentes na base.

Os atributos categóricos com valores yes/no foram transformados em 1/0. O atributo furnishingstatus foi transformado em: furnished = 2, semi-furnished = 1, unfurnished = 0.

5. Regressão Linear para estimar os valores das casas

Orientações:

- Separar atributos e alvo.
- Dividir treino e teste (teste 20%).
- Treinar e testar a regressão linear.
- Avaliar o modelo.

5.a) Qual o resultado para as seguintes métricas? (Pontuação: 15)

- R^2 (Coeficiente de Determinação): Quanto da variação dos preços o modelo consegue explicar.
- MAE (Mean Absolute Error): O erro médio absoluto entre valores reais e previstos.
- RMSE (Root Mean Squared Error): penaliza erros grandes, causados, por exemplo, por valores extremos (outliers).

Métrica	Resultado
R^2	0,6126
MAE	761.468,13
RMSE	1.074.924,71

5.b) Qual a função linear gerada? (Pontuação: 10)

Resultado:

$$\text{price} = -324.318,36 + 248,64 \cdot \text{area} + 121.988,74 \cdot \text{bedrooms} + 1.042.889,09 \cdot \text{bathrooms} + 389.071,80 \cdot \text{stories} + 387.693,78 \cdot \text{mainroad} + 356.461,09 \cdot \text{guestroom} + 380.711,35 \cdot \text{basement} + 751.717,52 \cdot \text{hotwaterheating} + 823.004,16 \cdot \text{airconditioning} + 295.891,21 \cdot \text{parking} + 635.695,43 \cdot \text{prefarea} + 221.796,97 \cdot \text{furnishingstatus}$$

5.c) Quais variáveis influenciaram mais o preço? (Pontuação: 5)

Variável	Coefficiente	Coefficiente padronizado
area	248,64	0,2885
bathrooms	1.042.889,09	0,2802
airconditioning	823.004,16	0,2047
stories	389.071,80	0,1804
prefarea	635.695,43	0,1442

A influência foi ordenada pelo valor absoluto do coeficiente padronizado, pois isso permite comparar variáveis em escalas diferentes.

6. Realizar 4 classificações conforme orientações abaixo (Pontuação: 15)

Algoritmos utilizados:

- LDA (Linear Discriminant Analysis)
- Árvore de Decisão
- KNN
- Naive Bayes

Usar Cross Validation = 10 folds.

Para cada um dos algoritmos de classificação:

- Calcular e exibir a acurácia média;
- Gerar e exibir a matriz de confusão;

Será necessário criar um novo atributo(classe), conforme código a seguir. As classes serão: BaixoPadrão, MédioPadrão e AltoPadrão. Serão atribuídas as classes conforme intervalo do preço.

Python

```
import numpy as np
import pandas as pd

menor = df['price'].min()
maior = df['price'].max()

amplitude = maior - menor
intervalo = amplitude / 3

valor1 = menor + intervalo
```

```

valor2 = menor + (2 * intervalo)

# Criar categorias
df['ClassePadrao'] = pd.cut(
    df['price'],
    bins=[-np.inf, valor1, valor2, np.inf],
    labels=['BaixoPadrão', 'MédioPadrão', 'AltoPadrão'],
    include_lowest=True
)

```

Resultado:

O melhor resultado foi obtido pelo algoritmo KNN, com acurácia média de 83,89%.

Algoritmo	Acurácia média
LDA	83,55%
Árvore de Decisão	82,58%
KNN	83,89%
Naive Bayes	45,52%

Matrizes de Confusão

Matriz de confusão - LDA

Real \ Previsto	BaixoPadrão	MédioPadrão	AltoPadrão
BaixoPadrão	369	34	0
MédioPadrão	44	83	3
AltoPadrão	0	9	3

Matriz de confusão - Árvore de Decisão

Real \ Previsto	BaixoPadrão	MédioPadrão	AltoPadrão
BaixoPadrão	369	34	0
MédioPadrão	50	78	2
AltoPadrão	5	4	3

Matriz de confusão - KNN

Real \ Previsto	BaixoPadrão	MédioPadrão	AltoPadrão
-----------------	-------------	-------------	------------

BaixoPadrão	376	27	0
MédioPadrão	50	80	0
AltoPadrão	2	9	1

Matriz de confusão - Naive Bayes

Real \ Previsto	BaixoPadrão	MédioPadrão	AltoPadrão
BaixoPadrão	129	265	9
MédioPadrão	0	115	15
AltoPadrão	0	8	4

7. Realizar o agrupamento, utilizando o algoritmo K-Means. (Pontuação: 10)

Instruções:

- Formar 3 grupos.
- Representar os grupos graficamente.

Resultado do Agrupamento (K-Means - 3 Grupos):

Grupo	Qtd.	Preço médio	Área média	Quartos	Banheiros
1	77	3.398.904,5 5	3.606,44	2,99	1,23
2	186	6.687.236,2 4	6.877,58	3,32	1,61
3	282	3.873.495,9 2	4.433,05	2,72	1,09

Representação gráfica dos 3 grupos gerados pelo K-Means:

K-Means com 3 grupos - projecao PCA 2D

