

Projeto Final – Mineração de Dados – DSM - Prof. Adriana Talhari

Nome: _____

Projeto – Parte 1: Regras de Associação (Apriori e FP-Growth)

Objetivo: Aplicar algoritmos de regras de associação para identificar padrões de consumo em uma plataforma de streaming, interpretar os resultados obtidos e relacioná-los ao processo de tomada de decisão.

Base de Dados: BaseStreamingNominalApenasTrue.arff

Codificar em Python. Evidenciar resposta neste documento. Enviar código e este documento até o prazo de entrega.

1) Geração das regras (Pontuação: 15)

Utilizar os algoritmos:

- Apriori
- FP-Growth

Considerar:

- suporte mínimo = 20%
- confiança mínima = 80%

Quais foram as 14 regras mais fortes encontradas nos algoritmos? Para cada regra apresentar: antecedente, consequente, suporte e confiança.

2) Demonstração matemática do cálculo do suporte e da confiança das 3 regras com maior confiança (Pontuação: 15)

- a) Quantidade de ocorrências dos antecedentes
- b) Quantidade de ocorrências da regra completa
- c) Cálculo do suporte da regra
- d) Cálculo da confiança da regra

Exemplo de Regra: Acao → FiccaoCientifica

3) Interpretação de algumas das regras (sugestão 3 regras) e explicação de algumas ações que poderiam ser tomadas com base nos padrões encontrados. (Pontuação: 10)

Projeto – Parte 2: Pré-processamento, Regressão, Classificação e Agrupamento

Objetivo: Aplicar algoritmos de Regressão Linear para estimar os valores das casas. Comparar alguns algoritmos de Classificação. Realizar a tarefa de agrupamento de dados.

Base de Dados: <https://www.kaggle.com/datasets/yasserh/housing-prices-dataset>

Codificar em Python. Evidenciar resposta neste documento. Enviar código e este documento até o prazo de entrega.

4) Pré-processamento dos Dados (Pontuação: 5)

Verificar se existe dados ausentes. Se sim, em quais atributos? Se ausente, preencher com média ou moda do atributo.

Realizar as seguintes transformações nos dados:

- Atributos categórico preenchidos com “yes” ou “no” viram numéricos:
 - yes = 1
 - no = 0
- Atributo “furnishingstatus” vira numérico:
 - furnished = 2,
 - semi-furnished = 1,
 - unfurnished = 0

5) Realizar a Regressão Linear para estimar os valores das casas, seguindo as seguintes orientações:

Separar atributos e alvo

Dividir treino e teste (teste 20%)

Treinar e testar a regressão linear

Avaliar o modelo

5. a) Qual o resultado para as seguintes métricas? (Pontuação: 15)

R^2 (Coeficiente de Determinação): Quanto da variação dos preços o modelo consegue explicar.

MAE (Mean Absolute Error): O erro médio absoluto entre valores reais e previstos.

RMSE (Root Mean Squared Error): penaliza erros grandes, causados, por exemplo, por valores extremos (outliers).

5. b) Qual a função linear gerada? (Pontuação: 10)

5. c) Quais variáveis influenciaram mais o preço? (Pontuação: 5)

6) Realizar 4 classificações conforme orientações abaixo (Pontuação: 15):

LDA (Linear Discriminant Analysis)

Árvore de Decisão

KNN

Naive Bayes

Usar Cross Validation = 10 folds.

Para cada um dos algoritmos de classificação:

- Calcular e exibir a acurácia média;
- Gerar e exibir a matriz de confusão;

Será necessário criar um novo atributo(classe), conforme código a seguir. As classes serão: BaixoPadrão, MédioPadrão e AltoPadrão. Serão atribuídas as classes conforme intervalo do preço.

```
import numpy as np

menor = df['price'].min()
maior = df['price'].max()

amplitude = maior - menor
intervalo = amplitude / 3

valor1 = menor + intervalo
valor2 = menor + (2 * intervalo)

# Criar categorias
df['ClassePadrao'] = pd.cut(
    df['price'],
    bins=[-np.inf, valor1, valor2, np.inf],
    labels=['BaixoPadrão', 'MédioPadrão', 'AltoPadrão'],
    include_lowest=True
)
```

Qual dos 4 algoritmos apresentou o melhor resultado?

7) Realizar o agrupamento, utilizando o algoritmo K-Means. (Pontuação: 10)

Formar 3 grupos

Representar os grupos graficamente