

Atividade Extra 2 – PLN

Nome: Mauro do Prado Santos

Questão 1

O modelo de embeddings utilizado na Atividade 2 é:

sentence-transformers/all-MiniLM-L6-v2

Esse modelo pertence à biblioteca **Sentence-Transformers (Hugging Face)** e roda localmente, sem necessidade de API externa.

Questão 2

Na Atividade 2, não é utilizado um modelo da OpenAI.

O modelo de linguagem gerativo usado é um modelo open-source: **google/flan-t5-base**

Ou seja:

- Atividade 1 → GPT-4.1-mini (OpenAI, remoto)
 - Atividade 2 → Flan-T5 (local, via Hugging Face Transformers)
-

Questão 3

A biblioteca **LangChain** serve para orquestrar aplicações com modelos de linguagem.

Ela facilita:

- integração entre modelos (LLMs e embeddings)
- criação de pipelines (RAG, agentes, chains)
- gerenciamento de contexto
- conexão com bases de dados vetoriais

No contexto do notebook, ela ajuda a organizar o fluxo de:

Questão 4

Na Atividade 2, a tokenização é feita com o tokenizer do modelo Hugging Face (Flan-T5).

Características:

- baseada em subwords (SentencePiece)
 - limite de tokens (ex: 512 tokens de entrada)
 - o texto é convertido em IDs numéricos antes de entrar no modelo
 - controle explícito do tamanho do input (diferente da API da OpenAI que abstrai isso)
-

Questão 5

A biblioteca **Transformers (Hugging Face)** é responsável por:

- carregar o modelo de linguagem (Flan-T5)
- carregar o tokenizer
- executar inferência local (geração de texto)
- gerenciar entrada/saída em formato de tokens

Ou seja, ela substitui completamente a API da OpenAI na Atividade 2.

Questão 6

Significado dos parâmetros da classe `RAGConfig`:

- **top_k: int = 4**
Número de chunks recuperados do índice vetorial para compor o contexto.
 - **max_input_tokens: int = 512**
Limite máximo de tokens que o modelo pode receber como entrada.
 - **reserved_for_prompt_tokens: int = 180**
Parte dos tokens reservada para o prompt (instruções + pergunta), garantindo que não falte espaço.
 - **max_new_tokens: int = 256**
Quantidade máxima de tokens que o modelo pode gerar como resposta.
-

Questão 7

“Orçamento de tokens” é o controle do número total de tokens usados na entrada do modelo.

Como o modelo tem limite (ex: 512 tokens), o sistema precisa:

- reservar espaço para o prompt
- limitar o tamanho do contexto recuperado
- evitar truncamento

Na prática, é a divisão entre:

- tokens do prompt
 - tokens do contexto
 - tokens da resposta
-

Questão 8

O prompt atual usa RAG porque inclui:

CONTEXTO:

```
{context}
```

Sem RAG, o prompt seria algo como:

```
prompt = f"""Você é um assistente acadêmico. Responda em português.  
Responda de forma clara, objetiva e bem estruturada.  
Não repita a pergunta.
```

PERGUNTA:

```
{question}
```

RESPOSTA: """

Ou seja:

- não haveria contexto externo
- o modelo dependeria apenas do conhecimento interno
- maior risco de erro ou alucinação