

 Tema

Chatbot institucional baseado em dados estruturados (JSON) com apoio de modelos de linguagem (LLMs). Esta atividade explora o uso de modelos de linguagem de grande porte como ferramentas de apoio à consulta, e não como fontes primárias de conhecimento, em um cenário onde os dados estão previamente organizados em estruturas formais (JSON). O foco está na integração entre técnicas de PLN e princípios de engenharia de software para construção de sistemas confiáveis, rastreáveis e livres de alucinação.

 Objetivos da Atividade

- Compreender o papel dos LLMs como interfaces de consulta sobre dados estruturados;
- Analisar criticamente as limitações de pipelines baseados apenas em recuperação semântica (RAG);
- Identificar situações em que filtros estruturados são necessários para garantir correção lógica e numérica;
- Diferenciar problemas de recuperação de contexto de falhas do modelo de linguagem;
- Desenvolver uma visão de engenharia de sistemas de PLN, com foco em controle, rastreabilidade e robustez.

 Requisitos de Avaliação

- Valor: 0,25 pts. na média final.
- Forma de entrega: individual.
- Critério obrigatório: responder à arguição do professor com base nas perguntas norteadoras.
- Data de entrega: a definir.

 Sobre o Notebook

Este notebook (`Atividade3.ipynb`) implementa, de forma incremental, um pipeline completo de chatbot baseado em dados estruturados, contemplando desde o carregamento dos arquivos JSON até a geração final das respostas em linguagem natural.

Estrutura geral do notebook**1. Instalação e importação de bibliotecas**

Configuração do ambiente e das dependências necessárias para manipulação de dados, embeddings e modelos de linguagem.

2. Acesso ao Google Drive e carregamento dos dados

Leitura automática de todos os arquivos JSON a partir de uma pasta definida pelo usuário.

3. Descrição e normalização dos dados estruturados

Organização dos dados em estruturas internas consistentes, preparando-os para indexação e consulta.

4. Construção de índice vetorial (FAISS)

Indexação de documentos derivados dos JSONs para permitir recuperação semântica (RAG).

5. Função de resposta (answer)

Implementação do fluxo:

- pergunta em linguagem natural → recuperação de contexto → envio do contexto ao LLM → geração da resposta.

6. Análise crítica do pipeline

Discussão prática, por meio dos exercícios, das limitações do uso exclusivo de embeddings para:

- filtros simbólicos (ex.: dia da semana);
- cálculos agregados (ex.: somatórios de carga horária).

7. Exercícios guiados

Os exercícios propostos exploram cenários em que o sistema falha, incentivando o aluno a:

- inspecionar o contexto recuperado;
- identificar a origem do erro;
- propor melhorias na etapa de recuperação e filtragem.

Dados utilizados nos arquivos JSON

O corpus da atividade é composto por arquivos JSON que descrevem informações acadêmicas do curso de DSM:

- Calendário acadêmico (calendario-2026.json);
- Horários das disciplinas (dsm-horario-2026-1.json);
- Matriz curricular (dsm-matriz-curricular.json).

Esses dados permitem consultas de natureza variada, como listagens, filtros temporais, consultas por professor e agregações numéricas, servindo como base concreta para discutir as vantagens e limitações das abordagens adotadas.

Exercícios

Exercício 1 – Recuperação (RAG) com filtro estruturado para “segunda-feira”

Enunciado: Ao executar o chatbot com a pergunta abaixo, o sistema gerou uma resposta parcial:

Pergunta (ou 'sair'): quais são os professores que dão aula na segunda-feira?

R: Os professores que dão aula na segunda-feira são:

1. Henrique Duarte Borges Louro - Disciplina: Técnicas de Programação I
2. André Olímpio - Disciplina: Engenharia de Software II
3. Álvaro Alexandre Rezende Gonçalves - Disciplina: Programação para Dispositivos Móveis II

Contudo, ao inspecionar o contexto recuperado (`top_k = 15`), observa-se que ele contém muitos registros que não correspondem à segunda-feira (por exemplo, “Qui”, “Sex”, “Qua”), além de itens de outro domínio (calendário acadêmico). Isso evidencia que a etapa de recuperação trouxe contexto parcialmente irrelevante.

Observação: Para visualizar o contexto na execução, habilite o `print(f"Contexto:\n{context_text}")` na função `answer`.

Contexto:

Horário DSM | Semestre: 4º | Disciplina: Inglês II | Professor: Maria Lucia de Oliveira | Horários: Sex 21:25-23:05
Horário DSM | Semestre: 3º | Disciplina: Inglês I | Professor: Maria Lucia de Oliveira | Horários: Qui 21:25-23:05
Horário DSM | Semestre: 2º | Disciplina: Técnicas de Programação I | Professor: Henrique Duarte Borges Louro | Horários: Seg 18:45-22:15
Horário DSM | Semestre: 6º | Disciplina: Ética Profissional e Patente | Professor: Ali Antonio Abrão Junior | Horários: Ter 22:15-23:05, Qua 22:15-23:05
Horário DSM | Semestre: 2º | Disciplina: Matemática para Computação | Professor: Fabrício Galende Marques de Carvalho | Horários: Qui 18:45-22:15
Horário DSM | Semestre: 2º | Disciplina: Banco de Dados Relacional | Professor: Lucineide Nunes Pimenta | Horários: Ter 21:25-23:05, Sex 21:25-23:05
Horário DSM | Semestre: 2º | Disciplina: Desenvolvimento Web II | Professor: Arley Ferreira de Souza | Horários: Ter 18:45-21:15, Qua 22:15-23:05
Calendário Acadêmico 2026 | Evento: Não haverá aula – Dia do Professor (Decreto Federal nº 52.682/1963) | Data: 2026-10-15 até 2026-10-15
Horário DSM | Semestre: 6º | Disciplina: Inglês IV | Professor: Viviane Marengoni Garo | Horários: Qui 18:45-20:25
Horário DSM | Semestre: 3º | Disciplina: Técnicas de Programação II | Professor: Henrique Duarte Borges Louro | Horários: Qui 18:45-21:15, Seg 22:15-23:05
Horário DSM | Semestre: 5º | Disciplina: Inglês III | Professor: Viviane Marengoni Garo | Horários: Sex 18:45-20:25
Horário DSM | Semestre: 2º | Disciplina: Engenharia de Software II | Professor: André Olímpio | Horários: Sex 18:45-21:15, Seg 22:15-23:05
Horário DSM | Semestre: 2º | Disciplina: Estrutura de Dados | Professor: Fabrício Galende Marques de Carvalho | Horários: Qua 18:45-22:15
Horário DSM | Semestre: 3º | Disciplina: Álgebra Linear | Professor: Anderson José da Silva Zamingnani | Horários: Qua 18:45-22:15
Horário DSM | Semestre: 5º | Disciplina: Programação para Dispositivos Móveis II | Professor: Álvaro Alexandre Rezende Gonçalves | Horários: Qui 20:25-23:05, Seg 22:15-23:05

Diagnóstico: O problema mais provável está na etapa de recuperação (FAISS + embeddings), porque:

- Embeddings são bons para recuperar “coisas relacionadas a horários”, mas não garantem obedecer a restrições simbólicas exatas como “segunda-feira”.
- Com `top_k=15`, o sistema não está filtrando os resultados por dia da semana; ele apenas recupera textos semanticamente próximos.
- Como consequência, o modelo recebe um contexto “poluído” e responde usando apenas os itens que ele encontra sobre “Seg”, possivelmente deixando de fora professores que também lecionam na segunda-feira.

Tarefa: Implemente alguma melhoria para melhorar a recuperação de dias da semana no horário.

Exercício 2 – Recuperação (RAG) com filtro estruturado para cálculo de somatórios

Enunciado: Ao executar o chatbot com a pergunta abaixo, o sistema gerou uma resposta incorreta, o total são 480 horas:

Pergunta (ou 'sair'): qual é a carga horária do 5o semestre?

R: A carga horária total do 5º semestre do curso de DSM é de 400 horas. Isso inclui as seguintes disciplinas:

- Segurança no Desenvolvimento de Aplicações: 80h
- Aprendizagem de Máquina: 80h
- Computação em Nuvem I: 80h
- Programação para Dispositivos Móveis II: 80h
- Inglês III: 40h
- Lab. de Des. para Dispositivos Móveis: 80h

Diagnóstico: O erro não está no modelo de linguagem, mas na etapa de recuperação do contexto que antecede o cálculo do somatório. Ao inspecionar o contexto recuperado (top_k = 15), verifica-se que:

- Nem todas as disciplinas do **5º semestre** foram corretamente recuperadas antes do cálculo.
- O contexto contém **registros de outros semestres (2º, 4º e 6º)**, que são irrelevantes para a pergunta.
- Há também **mistura de domínios**, com registros de horários de aula sendo recuperados junto com dados da matriz curricular.

Como consequência, o modelo realizou o somatório apenas sobre um **subconjunto incompleto das disciplinas do 5º semestre**, resultando em um valor incorreto.

Contexto:

Curso: DSM | Semestre: 5º | Disciplina: Segurança no Des. de Aplicações | Carga Horária: 80h | Modalidade: presencial
Curso: DSM | Semestre: 5º | Disciplina: Aprendizagem de Máquina | Carga Horária: 80h | Modalidade: presencial
Curso: DSM | Semestre: 5º | Disciplina: Computação em Nuvem I | Carga Horária: 80h | Modalidade: presencial
Curso: DSM | Semestre: 5º | Disciplina: Programação para Dispositivos Móveis II | Carga Horária: 80h | Modalidade: presencial
Curso: DSM | Semestre: 5º | Disciplina: Inglês III | Carga Horária: 40h | Modalidade: remota
Curso: DSM | Semestre: 2º | Disciplina: Matemática para Computação | Carga Horária: 80h | Modalidade: presencial
Curso: DSM | Semestre: 4º | Disciplina: Inglês II | Carga Horária: 40h | Modalidade: presencial
Curso: DSM | Semestre: 4º | Disciplina: Integração e Entrega Contínua | Carga Horária: 80h | Modalidade: presencial
Curso: DSM | Semestre: 4º | Disciplina: Estatística Aplicada | Carga Horária: 80h | Modalidade: presencial
Curso: DSM | Semestre: 4º | Disciplina: Internet das Coisas e Aplicações | Carga Horária: 80h | Modalidade: presencial
Horário DSM | Semestre: 5º | Disciplina: Segurança no Desenvolvimento de Aplicações | Professor: Rodrigo Silva Peres | Horários: Seg 18:45-22:15
Horário DSM | Semestre: 5º | Disciplina: Laboratório de Desenvolvimento para Dispositivos Móveis | Professor: Álvaro Alexandre Rezende Gonçalves | Horários: Qui 18:45-22:15, Ter 21:25-23:05
Curso: DSM | Semestre: 6º | Disciplina: Ética Profissional e Patente | Carga Horária: 40h | Modalidade: remota
Horário DSM | Semestre: 5º | Disciplina: Computação em Nuvem I | Professor: Ronaldo Emerick Moreira | Horários: Qua 18:45-22:15

Curso: DSM | Semestre: 5º | Disciplina: Lab. de Des. para Dispositivos Móveis |
Carga Horária: 80h | Modalidade: presencial

Análise conceitual: Este exercício evidencia uma limitação importante do uso de RAG em perguntas que envolvem agregações numéricas:

Cálculos de somatório exigem contexto completo e corretamente filtrado.

Embeddings são adequados para recuperar conteúdos semanticamente relacionados, mas **não garantem** que:

- todos os itens relevantes (ex.: todas as disciplinas de um semestre) sejam recuperados;
- itens irrelevantes (outros semestres ou outros domínios) sejam excluídos antes do cálculo.

Assim, quando a recuperação é imprecisa, o erro se propaga diretamente para o resultado numérico.

Tarefa: Explique **por que o sistema apresenta dificuldade em calcular somatórios corretamente** quando depende exclusivamente de recuperação semântica (RAG), considerando:

- a presença de registros irrelevantes no contexto;
- a ausência de garantia de completude na recuperação;
- a mistura de domínios de dados antes do cálculo.

Sua resposta deve se concentrar nos **aspectos técnicos da recuperação e do preparo do contexto**, e não no modelo de linguagem em si.