

Objetivos da aula:

- Compreender o que é o Processamento de Linguagem Natural (PLN), seu escopo e sua importância no contexto da IA e do desenvolvimento de software.
- Reconhecer as principais aplicações do PLN em sistemas computacionais modernos, especialmente aquelas baseadas em processamento de texto.
- Entender o texto como dado bruto, identificando ruídos e desafios que impedem seu uso direto em algoritmos de Aprendizado de Máquina.
- Compreender o pipeline de processamento de texto como um fluxo de engenharia de software, composto por etapas bem definidas de transformação dos dados.
- Aplicar conceitualmente e na prática as etapas básicas do processamento de texto, incluindo: limpeza (uso de expressões regulares), normalização, tokenização, remoção seletiva de stopwords e redução morfológica.
- Implementar, em Python, um pipeline básico de processamento de texto, utilizando código simples e transparente, de modo a visualizar o impacto de cada etapa sobre o texto.

Índice:

- i. Introdução ao Processamento de Linguagem Natural
- ii. Aplicações do Processamento de Linguagem Natural
- iii. Processamento de Texto

i. Introdução ao Processamento de Linguagem Natural **SLIDE 14**

Introdução

O Processamento de Linguagem Natural (PLN) é uma subárea da IA que se dedica ao estudo e ao desenvolvimento de métodos computacionais capazes de analisar, compreender, interpretar e gerar linguagem humana de forma automática.

A linguagem natural — falada ou escrita — é o principal meio de comunicação entre seres humanos. Permitir que sistemas computacionais interajam com esse tipo de linguagem representa um dos maiores desafios da computação moderna, pois envolve aspectos linguísticos, estatísticos, cognitivos e computacionais.

O PLN busca reduzir a distância entre a forma como humanos se comunicam e a forma como máquinas processam informações.

Linguagem Natural versus Linguagem Formal **SLIDE 15**

É importante distinguir linguagem natural de linguagens formais, como linguagens de programação.

- Linguagens formais:
 - Possuem sintaxe rígida

- São não ambíguas
- Foram projetadas para serem interpretadas por máquinas
- Exigem precisão absoluta
- Linguagem natural:
 - É ambígua
 - Depende de contexto
 - Evolui ao longo do tempo
 - Apresenta variações culturais, regionais e individuais

Exemplo de ambiguidade:

“Eu vi o homem com o telescópio.”

Essa frase admite múltiplas interpretações, algo trivial para humanos, mas extremamente complexo para sistemas computacionais.

Objetivo do PLN SLIDE 16

O objetivo central do PLN é permitir que computadores realizem tarefas úteis a partir de linguagem humana, tais como:

- Extrair informações relevantes de textos
- Classificar documentos
- Identificar sentimentos e opiniões
- Responder perguntas em linguagem natural
- Traduzir textos automaticamente
- Reconhecer e transcrever fala

Em termos práticos, o PLN procura responder à seguinte pergunta:

Como representar e manipular linguagem natural de forma computacional para que máquinas possam operar sobre ela com eficiência e significado?

PLN como área interdisciplinar SLIDE 17

O PLN é uma área intrinsecamente interdisciplinar, envolvendo conhecimentos de:

- Linguística: morfologia, sintaxe, semântica e pragmática
- Ciência da Computação: algoritmos, estruturas de dados e engenharia de software
- Aprendizado de Máquina: classificação, modelos probabilísticos e redes neurais
- Estatística e Matemática: probabilidade, otimização e análise de dados

Essa característica torna o PLN uma área tecnicamente rica, mas também conceitualmente desafiadora.

Abordagens históricas do PLN **SLIDE 18**

Ao longo do tempo, o PLN evoluiu por meio de diferentes paradigmas:

1. Abordagens baseadas em regras

- Uso intensivo de gramáticas e regras linguísticas
- Forte dependência de especialistas humanos
- Difícil manutenção e escalabilidade

2. Abordagens estatísticas

- Uso de grandes volumes de dados textuais
- Modelagem probabilística da linguagem
- Menor dependência de regras explícitas

3. Abordagens baseadas em Aprendizado de Máquina

- Uso de algoritmos supervisionados e não supervisionados
- Extração automática de padrões
- Melhor adaptação a diferentes domínios

4. Abordagens neurais (estado da arte)

- Representações distribuídas
- Modelos baseados em redes neurais profundas
- Forte dependência de dados e poder computacional

No contexto deste curso, o foco será compreender como essas abordagens se conectam, e como aplicá-las de forma prática no desenvolvimento de software.

Desafios fundamentais do PLN **SLIDE 19**

Alguns dos principais desafios enfrentados pela área incluem:

- Ambiguidade lexical e sintática

Exemplo clássico

“banco”

- banco de sentar
- banco de dinheiro

Frase:

“Vou ao banco”

 Sem contexto, o computador **não sabe qual banco é.**

-
- Dependência de contexto

- Ironia e sarcasmo
- Linguagem informal
- Multilinguismo

Exemplo simples do dia a dia

- Google Tradutor
- Chatbots que atendem em português, inglês e espanhol
- Assistentes de voz que mudam de idioma

Tudo isso envolve **multilinguismo**.

- Escassez de dados anotados em certos domínios



O que é escassez de dados anotados em certos domínios

Significa que **faltam dados** já “**marcados**” ou “**rotulados**” para treinar modelos em alguns assuntos específicos.

Ou, em linguagem ainda mais direta:

Em alguns temas, **não existe texto suficiente já explicado para o computador aprender**.



O que são dados anotados (rapidinho)

Explique assim para os alunos:

Dados anotados são textos que já vêm com uma “etiqueta”.

Exemplo:

- Texto: “O produto é ótimo”
→ Anotação: **positivo**
- Texto: “Veio com defeito”
→ Anotação: **negativo**

Essas anotações normalmente são feitas por pessoas.



O que é “domínio”

Domínio é o **assunto específico** do texto.

Exemplos de domínios:

- medicina
- direito

- finanças
 - engenharia
 - linguagem informal da internet
-

// Onde está o problema?

Para assuntos comuns, como redes sociais, existem muitos dados anotados.

Para assuntos específicos, como laudos médicos ou documentos jurídicos, quase não existem.

Por quê?

- dados são sensíveis
 - exigem especialistas
 - são caros de anotar
 - podem ter questões legais
-

Exemplo simples

É fácil achar textos rotulados como “feliz” ou “triste”.

É difícil achar textos médicos rotulados por médicos.

Esses desafios explicam por que o PLN continua sendo um campo ativo de pesquisa e inovação.

ii. Aplicações do Processamento de Linguagem Natural **SLIDE 20**

Introdução

O PLN não se limita a estudos teóricos sobre linguagem. Pelo contrário, trata-se de uma área fortemente orientada a aplicações práticas, amplamente utilizadas em sistemas computacionais modernos.

Atualmente, grande parte das interações entre usuários e sistemas digitais envolve algum tipo de processamento automático de texto ou fala, tornando o PLN um componente essencial no desenvolvimento de software inteligente.

Interação humano-computador **SLIDE 21**

Uma das aplicações mais visíveis do PLN está na interface entre humanos e computadores.

Exemplos:

- Chatbots
- Assistentes virtuais
- Sistemas de atendimento automatizado

- Interfaces conversacionais em aplicativos e websites

Nesses sistemas, o PLN é responsável por:

- Interpretar intenções do usuário
- Extrair informações relevantes da entrada textual ou falada
- Gerar respostas coerentes em linguagem natural

Classificação e organização de textos SLIDE 22

A classificação automática de textos é uma das aplicações mais tradicionais e consolidadas do PLN. Exemplos:

- Classificação de e-mails (spam / não spam)
- Categorização de notícias
- Organização de documentos corporativos
- Identificação de tópicos em textos

Essas aplicações normalmente utilizam:

- Técnicas de extração de características
- Algoritmos de Aprendizado de Máquina supervisionado
- Avaliação estatística de desempenho

Análise de sentimentos e opiniões SLIDE 23

A análise de sentimentos busca identificar a polaridade emocional expressa em um texto, como:

- Positiva
- Negativa
- Neutra

Exemplos de uso:

- Avaliações de produtos e serviços
- Comentários em redes sociais
- Feedback de usuários
- Monitoramento de reputação de marcas

Essa aplicação é especialmente relevante em contextos comerciais e sociais, pois permite transformar grandes volumes de texto em indicadores quantitativos.

Busca e recuperação de informação SLIDE 24

Sistemas de busca modernos dependem fortemente de PLN para:

- Interpretar consultas dos usuários
- Encontrar documentos relevantes
- Ordenar resultados por similaridade semântica

Diferentemente de buscas baseadas apenas em palavras-chave, sistemas com PLN conseguem:

- Considerar sinônimos
- Lidar com variações linguísticas
- Explorar o contexto da consulta

Tradução automática SLIDE 24

A tradução automática é uma das aplicações mais complexas e desafiadoras do PLN.

Ela envolve:

- Compreensão do significado do texto original
- Preservação de contexto
- Geração de texto fluente no idioma de destino

Apesar dos avanços recentes, a tradução automática ainda enfrenta dificuldades com:

- Expressões idiomáticas
- Ambiguidade
- Diferenças culturais

Reconhecimento e processamento de fala SLIDE 25

O PLN também está presente em aplicações que envolvem linguagem falada, normalmente integradas a sistemas de reconhecimento de voz.

Exemplos:

- Transcrição automática de áudio
- Comandos de voz
- Sistemas de legendagem
- Interfaces multimodais

Nesse contexto, o PLN atua principalmente após a conversão da fala em texto, realizando análise linguística e semântica.

Descoberta de conhecimento em textos – SLIDE 26

A Descoberta de Conhecimento em Textos (Knowledge Discovery in Texts – KDT) busca extrair padrões, informações e insights a partir de grandes coleções de documentos.

Aplicações incluem:

- Análise de tendências
- Extração de entidades e relacionamentos
- Resumo automático de textos
- Apoio à tomada de decisão

Essa área combina PLN, Aprendizado de Máquina e Mineração de Dados.

iii. Processamento de Texto SLIDE 27

Introdução

O processamento de texto é a etapa inicial e fundamental de qualquer sistema de PLN. Antes que técnicas de Aprendizado de Máquina ou modelos linguísticos possam ser aplicados, é necessário transformar o texto bruto em uma forma adequada para análise computacional.

Essa etapa envolve um conjunto de operações responsáveis por **limpar, normalizar, segmentar e estruturar o texto**, reduzindo ruídos e preparando os dados para etapas posteriores, como extração de características, análise sintática e interpretação semântica.

Texto bruto como dado de entrada SLIDE 28

O texto, tal como produzido por usuários ou coletado de fontes externas, normalmente apresenta características que dificultam sua análise direta, como:

- Uso inconsistente de letras maiúsculas e minúsculas
- Pontuação irregular
- Erros ortográficos
- Emojis, URLs e caracteres especiais
- Linguagem informal

Exemplo de texto bruto:

“Adorei o produto!!! Chegou super rápido 😊 Recomendo!!!”

Para um sistema computacional, esse texto precisa ser **preprocessado**, de modo que sua informação essencial seja preservada e o ruído reduzido.

Normalização textual SLIDE 29

A normalização consiste em tornar o texto mais uniforme, reduzindo variações superficiais que não agregam significado relevante à tarefa.

Principais técnicas de normalização:

- Conversão para letras minúsculas (*lowercasing*)
- Remoção ou padronização de pontuação
- Remoção de números (dependendo do domínio)
- Remoção de acentuação
- Tratamento de caracteres especiais

A normalização contribui para:

- Redução da dimensionalidade
- Melhoria da generalização dos modelos

- Simplificação do vocabulário

Tokenização SLIDE 30

A tokenização é o processo de segmentação do texto em unidades menores chamadas tokens.

Dependendo da aplicação, os tokens podem ser:

- Palavras
- Subpalavras
- Símbolos
- Sentenças

Exemplo:

Texto: “PLN é uma área da Inteligência Artificial.”

Tokens: [“pln”, “é”, “uma”, “área”, “da”, “inteligência”, “artificial”]

A tokenização é uma etapa crítica, pois erros nessa fase propagam-se para todas as etapas subsequentes.

Stopwords SLIDE 31

Stopwords são palavras que ocorrem com alta frequência na língua, mas que geralmente carregam pouco significado semântico para determinadas tarefas.

Exemplos em português:

- “de”, “a”, “o”, “que”, “em”, “para”

A remoção de stopwords pode:

- Reduzir ruído
- Diminuir a dimensionalidade dos dados
- Melhorar o desempenho de alguns modelos

Entretanto, essa técnica deve ser aplicada com cautela, pois em certas tarefas (como análise sintática ou tradução) essas palavras são essenciais.

Stemming e Lematização SLIDE 32

Essas técnicas têm como objetivo reduzir palavras a uma forma base, diminuindo variações morfológicas.

Stemming

é cortar a palavra para ficar só com a raiz.

- Processo heurístico
- Remove sufixos e prefixos
- Pode gerar palavras inexistentes

Exemplo:

- “computação”, “computador”, “computacional” → “comput”

Lematização

é transformar uma palavra na sua forma base, aquela que aparece no dicionário.

Ou, em linguagem bem direta:

É fazer palavras diferentes virarem a mesma palavra “principal”.

- Baseada em dicionários e regras linguísticas
- Retorna a forma canônica (lema)
- Mais precisa, porém mais custosa

Exemplo:

- “correndo”, “correu”, “corre” → “correr”

A escolha entre stemming e lematização depende do equilíbrio desejado entre precisão linguística e custo computacional.

Pipeline de processamento de texto SLIDE 33

Em aplicações reais, as técnicas de processamento de texto são organizadas em um pipeline, no qual cada etapa transforma o texto para a próxima.

Exemplo de pipeline típico:

1. Leitura do texto bruto
2. Normalização
3. Tokenização
4. Remoção de stopwords
5. Stemming ou lematização

A construção de pipelines bem definidos contribui para:

- Reprodutibilidade
- Manutenção do código
- Integração com modelos de Aprendizado de Máquina

Impacto do processamento de texto nos modelos SLIDE 34

As decisões tomadas durante o processamento de texto têm impacto direto no desempenho dos modelos de PLN.

Más escolhas podem levar a:

- Perda de informação relevante
- Introdução de viés
- Redução da capacidade de generalização

Por esse motivo, o processamento de texto deve ser visto como uma **etapa de engenharia**, e não apenas como uma limpeza automática de dados.

Exercícios

Exercício 1 – Construção do pipeline completo- SLIDE 33

Tarefa:

1. Organize todas as etapas estudadas em um pipeline sequencial.
2. Para cada etapa, indique explicitamente:
 - A entrada
 - O processamento realizado
 - A saída
3. Utilize o texto base

"Não gostei... o produto veio com defeito 🤬 http://exemplo.com"

Entrada geral do pipeline (texto bruto):

Esse texto contém ruídos estruturais e variações linguísticas que impedem seu uso direto em modelos de Aprendizado de Máquina.

Etapa 1 – Limpeza do texto (Regex)

Entrada: Texto bruto (string)

- xxxxxxxxxxxxxxxx

Processamento realizado:

- xxxxxxxxxxxxxxxx
- xxxxxxxxxxxxxxxx
- xxxxxxxxxxxxxxxx
- xxxxxxxxxxxxxxxx

Saída: Texto limpo (string)

- xxxxxxxxxxxxxxxx

Etapa 2 – Normalização textual

Entrada: Texto limpo (string)

- xxxxxxxxxxxxxxxx

Processamento realizado:

- xxxxxxxxxxxxxxxx
- xxxxxxxxxxxxxxxx

Saída: Texto normalizado (string)

- xxxxxxxxxxxxxxxx

Etapa 3 – Tokenização

Entrada: Texto normalizado (string)

- xxxxxxxxxxxxxxxx

Processamento realizado:

- Tokenização por palavras

Saída: Lista de tokens

- xxxxxxxxxxxxxxxx

Etapa 4 – Remoção de Stopwords

Entrada: Lista de tokens

- xxxxxxxxxxxxxxxx

Processamento realizado:

- xxxxxxxxxxxxxxxx
- xxxxxxxxxxxxxxxx

Saída: Lista de tokens filtrados

- xxxxxxxxxxxxxxxx

Etapa 5 – Redução morfológica

Entrada: Lista de tokens filtrados

- xxxxxxxxxxxxxxxx

Processamento realizado:

- xxxxxxxxxxxxxxxx

Saída: Lista de tokens reduzidos

- xxxxxxxxxxxxxxxx

14

xx

3. Tokenização

xx

4. Remoção seletiva de stopwords

xx

5. Redução morfológica usando lema

xx

7. Redução morfológica usando stemming

xx

16

- [illegible]

- [illegible]

- [illegible]

- [illegible]