

PLN

Processamento de Linguagem Natural



- Professor: Flávio A. Guardia
- Aulas: Terça-Feira
- Horário: 18:45 – 22:15 h

Aula 2 de **PLN**

Processamento de Linguagem Natural

Objetivos da Aula

- Compreender o papel das bibliotecas de PLN no pipeline
 - Identificar o que é automatizado e o que é responsabilidade do desenvolvedor
 - Utilizar NLTK e spaCy
 - Analisar impacto da normalização textual
 - Preparar dados para ML

Processamento de Texto com NLTK

Introdução

- Na aula anterior, o PLN foi abordado a partir da construção manual de um pipeline de processamento de texto.
 - Nesta aula, o foco desloca-se para o uso de bibliotecas especializadas em PLN.
 - Bibliotecas de PLN não implementam automaticamente todas as etapas do processamento.
 - Higienização e normalização continuam sendo responsabilidade do desenvolvedor.
 - O uso de bibliotecas deve ser entendido como apoio à engenharia do processamento.

Pipeline de Processamento de Texto em Perspectiva

- Higienização do texto (remoção de ruídos estruturais)
- Normalização (padronização de grafia)
- Tokenização
- Remoção de stopwords
- Redução morfológica
- Etapas iniciais → Engenharia de dados
- Etapas linguísticas → Biblioteca NLTK (Natural Language Toolkit)



A Biblioteca NLTK: Papel e Características

- Biblioteca tradicional de PLN em Python.
 - Amplamente utilizada em contextos acadêmicos e educacionais.
 - Oferece componentes linguísticos explícitos
 - Tokenização: **word_tokenize**
 - Stopwords em português
 - Stemming: **RSLPStemmer**

Operações **não** automatizadas pelo NLTK

- Remoção de URLs, emojis ou HTML.
- Normalização de caixa (maiúsculas/minúsculas).
- Tratamento de acentuação.
- Padronização de espaços.
- Essas tarefas permanecem sob responsabilidade do desenvolvedor.




Demonstração Prática com **NLTK**

- Higienização com expressões regulares.
 - Normalização com operações sobre Unicode.
 - Tokenização.
 - Remoção de stopwords.
 - Stemming.
 - Objetivo: visualizar cada transformação aplicada ao texto.

Processamento de Texto com spaCy


Introdução

- Biblioteca moderna de PLN.
 - Foco em desempenho, robustez e uso em produção.
 - Pipeline linguístico integrado baseado em modelos estatísticos treinados.




Pipeline Linguístico no **spaCy**

- Tokenização.
 - Identificação de stopwords.
 - Lematização.
 - Anotação morfossintática (POS tagging).
 - Segmentação em sentenças.
 - Executado automaticamente ao aplicar `nlp(texto)`.




Principais Características do **spaCy**

- Modelos linguísticos treinados por idioma.
- Tratamento adequado da negação no português.
- Representações estruturadas: Doc, Token, Span.
- Desempenho otimizado para grandes volumes.
- Integração natural com Machine Learning
(Aprendizado de Máquina).



Redução Morfológica no **spaCy**: Lematização


- t.text → texto original.
 - t.lemma_ → lema (forma canônica).
 - t.pos_ → classe gramatical.
 - Diferente do stemming, o lema é linguisticamente válido.
 - Maior precisão implica maior custo computacional.





Demonstração prática com **spaCy**

- A demonstração prática apresentada no notebook **Aula 2 – Pipeline de Processamento de Texto com spaCy.ipynb** implementa um pipeline completo e autocontido



spaCy, NLTK e o Papel do Desenvolvedor

- Não existe biblioteca universalmente superior.
 - NLTK → ensino e experimentação.
 - spaCy → aplicações robustas e produção.
 - O desenvolvedor define pré-processamento, interpreta saídas e avalia impactos.

Exercícios

- Segue arquivo