

# PLN

## Processamento de Linguagem Natural



- Professor: Flávio A. Guardia
- Aulas: Terça-Feira
- Horário: 18:45 – 22:15 h

# Aula 3 de **PLN**

Processamento de Linguagem Natural

# Objetivos da Aula

- Compreender a extração de características
- Representar textos com Bag-of-Words, frequência de termos e n-grams
- Entender TF-IDF
- Identificar limitações dos modelos de contagem
- Compreender Word Embeddings
- Analisar similaridade semântica
- Avaliar limitações dos embeddings


# Índice

- Representação Vetorial do Texto
- Ponderação de Termos – TF-IDF
- Word Embeddings



# Representação Vetorial do Texto

- Como transformar texto em uma forma numérica adequada para algoritmos de Machine Learning?
- Processo: Extração de características → conversão de texto em vetores numéricos.



# Texto como dado estruturado

- Texto no PLN pode ser representado como:
  - Listas de tokens
  - Vetores numéricos
  - Matrizes documento-termo
- Cada documento é representado por um vetor de características.

# Modelo Bag-of-Words (BoW)

- Representa um texto como conjunto de palavras.
- Ignora a ordem das palavras.
- Considera:
- Quais palavras aparecem
- Quantas vezes aparecem.



# Exemplo Bag-of-Words

- Vocabulário:  
[produto, bom, ruim, qualidade]
- Texto:  
[produto, bom, qualidade]
- Representação:  
[1, 1, 0, 1]



# Frequência de Termos

- Extensão do Bag-of-Words.
- Cada dimensão indica quantas vezes o termo aparece.
- Exemplo:
- Texto: [produto, produto, bom]
- Vetor: [2,1]

# N-grams

- Sequências contíguas de tokens.

É um conjunto de itens consecutivos, sem pular nenhum no meio.

- Exemplo:

- Texto: [não, gostei, produto]

- Unigrams: ( $n = 1$ ) [não, **gostei**, produto]

- Bigrams: ( $n = 2$ ) [não **gostei**, **gostei** produto]

- ***Aumento de Custo Computacional !!!***

# Limitações dos Modelos de Contagem


- Ausência de semântica
- Perda da ordem global
- Alta dimensionalidade
- Sensibilidade lexical

# Ponderação de Termos

- Nem todas as palavras têm a mesma importância.
- Palavras muito frequentes carregam pouca informação.
- Termos raros tendem a ser mais informativos.


# Term Frequency (TF)

- Mede quantas vezes um termo aparece em um documento.
- Reflete a importância local do termo.



# Inverse Document Frequency (IDF)

- Mede o quão raro um termo é no conjunto de documentos.
- Palavras muito comuns recebem peso menor.






# Modelo TF-IDF


- Combina TF e IDF.
- Termo importante:
- Aparece muito em um documento
- Aparece pouco no restante do corpus

#matriz documento-termo ponderada




# Word Embeddings

- Representações vetoriais densas de palavras.
- Palavras semanticamente semelhantes ficam próximas no espaço vetorial.
- Baseado na hipótese distribucional.
- Exemplo: `fastText PT.ipynb`



# Espaço Vetorial Semântico

- Cada palavra é representada por um vetor.
- A similaridade é medida pela proximidade **entre vetores**.



# Similaridade Semântica

- Exemplo esperado:
- • bom  $\approx$  ótimo (vetores próximos)
- • bom  $\neq$  ruim (vetores distantes)

# Embeddings Pré-treinados

- Modelo utilizado: fastText
- Treinado com dados do Common Crawl
- Corpus com bilhões de tokens
- Vocabulário  $\approx$  2 milhões de palavras



# Embeddings Pré-treinados



# Dimensionalidade

- Cada palavra representada por vetor de 300 dimensões.
- Dimensões não possuem significado linguístico direto.

$$\vec{w} = (w_1, w_2, w_3, \dots, w_{300})$$



# Dimensionalidade

## Exemplo ilustrativo em baixa dimensão (3D)


Para fins didáticos, considere um exemplo simplificado em apenas 3 dimensões. que podemos visualizar intuitivamente.

Suponha os seguintes vetores (fictícios):

- bom  $\rightarrow (0.8, 0.1, 0.2)$
- ótimo  $\rightarrow (0.75, 0.15, 0.25)$
- ruim  $\rightarrow (-0.7, -0.2, 0.1)$

Nesse espaço tridimensional:

- os vetores de “**bom**” e “**ótimo**” apontam para direções semelhantes;
- o vetor de “**ruim**” aponta para uma direção diferente;
- a proximidade angular entre “bom” e “ótimo” indica **similaridade semântica**;
- a distância angular entre “bom” e “ruim” indica **oposição semântica**.





# Limitações dos Word Embeddings

- Representação estática
- Polissemia
- Dependência do corpus
- Viés dos dados

# Exercício em Aula

- Comparar:
- Bag-of-Words
- Frequência de termos
- TF-IDF
- Word Embeddings
- Utilizando dois textos fornecidos.