

Objetivos da aula:

- Compreender por que a estrutura sintática é um componente fundamental na construção de significado em sentenças da linguagem natural.
- Reconhecer as limitações de abordagens que tratam o texto apenas como palavras ou vetores semânticos isolados, sem considerar relações estruturais.
- Explicar o papel histórico da análise sintática no PLN, desde abordagens baseadas em regras explícitas até sua incorporação implícita em modelos modernos.
- Diferenciar as duas principais formas de representação sintática utilizadas no PLN: árvores de constituintes e estruturas de dependência, identificando seus pressupostos, vantagens e limitações.
- Compreender o processo de parsing sintático automático, bem como os desafios associados à ambiguidade estrutural.
- Interpretar grafos de dependência gerados por parsers reais, identificando núcleo, sujeito, objeto e modificadores em sentenças do português.
- Relacionar a análise sintática à extração de relações e informações estruturadas em aplicações práticas de PLN.
- Estabelecer uma conexão conceitual clara entre a análise sintática explícita e a forma como modelos baseados em atenção aprendem regularidades estruturais de maneira implícita.

Índice:

- i. A Estrutura como Alicerce do Sentido
- ii. Representações Sintáticas – Constituintes vs. Dependências
- iii. Parsing – O Processo de Análise Sintática Automática
- iv. Aplicações e a Extração de Relações Sintáticas

i. A Estrutura como Alicerce do Sentido**Contextualização SLIDE 4**

Até agora, aprendemos a transformar palavras em números. Vimos que modelos como o Bag-of-Words tratam o texto como um “saco de palavras” e que os Word Embeddings permitem capturar relações semânticas entre termos isolados, projetando palavras em um espaço vetorial contínuo.

Essas abordagens representam um avanço importante, mas compartilham uma limitação fundamental: elas não consideram explicitamente a estrutura interna das frases.

A linguagem humana, no entanto, não é apenas uma lista de palavras semanticamente relacionadas. O significado emerge não apenas *do que* é dito, mas *de como* as palavras se organizam.

Considere a diferença entre as duas sentenças a seguir: **SLIDE 5**

- *O cão mordeu o homem.*

- *O homem mordeu o cão.*

As palavras são exatamente as mesmas. Os vetores semânticos associados a cada termo também seriam os mesmos. Ainda assim, o significado global das frases é completamente diferente.

O que muda não é a semântica das palavras isoladas, mas a estrutura sintática da frase.

Este capítulo marca, portanto, uma transição conceitual importante no curso:

do processamento de palavras isoladas para o processamento de frases estruturadas.

Por que a sintaxe é fundamental no PLN? SLIDE 6

No contexto do PLN, a análise sintática responde a uma pergunta central:

Como modelar computacionalmente a organização gramatical das sentenças?

A sintaxe desempenha um papel estratégico no PLN porque permite tornar explícitas relações que não podem ser inferidas apenas a partir da proximidade semântica entre palavras.

De forma geral, a análise sintática cumpre três funções fundamentais:

- **Desambiguação gramatical**

Permite identificar a categoria e a função de uma palavra de acordo com seu contexto.

Exemplo: distinguir se uma palavra atua como substantivo ou verbo em uma frase específica.

- **Identificação de papéis sintáticos**

Torna explícito quem exerce a ação (sujeito), qual é a ação (verbo) e quem ou o que recebe essa ação (objeto).

- **Extração de relações estruturais**

Permite modelar relações entre núcleos e modificadores, como adjuntos, complementos e orações subordinadas.

Sem essas informações estruturais, muitos sistemas de PLN ficam restritos a interpretações superficiais do texto.

A evolução do pensamento sintático no PLN SLIDE 7

Para compreender o papel da análise sintática no PLN moderno, é fundamental observar como essa noção evoluiu ao longo do tempo.

A era das regras (PLN clássico)

Durante décadas, a análise sintática foi considerada um **passo obrigatório** no processamento de linguagem. Sistemas clássicos seguiam um pipeline rígido:

tokenização → análise morfológica → análise sintática → interpretação semântica

Nessa abordagem:

- regras gramaticais eram explicitamente codificadas;
- árvores sintáticas eram construídas antes de qualquer tarefa semântica;
- a sintaxe funcionava como um “pedágio” obrigatório para o entendimento do texto.

Embora teoricamente elegante, esse modelo apresentava limitações práticas significativas, como alto custo de manutenção, baixa robustez a erros e dificuldade de escalabilidade.

A era do aprendizado (PLN moderno) **SLIDE 7**

Com o avanço dos modelos estatísticos e, posteriormente, das redes neurais profundas, essa visão começou a mudar.

Modelos modernos — especialmente os baseados na arquitetura Transformer — **não utilizam regras gramaticais explícitas** nem constroem árvores sintáticas como etapa intermediária obrigatória. Ainda assim, eles conseguem:

- capturar dependências de longo alcance;
- modelar relações sintáticas complexas;
- produzir representações sensíveis ao contexto da frase.

A sintaxe, nesse novo paradigma, **não desaparece**, mas passa a ser **aprendida implicitamente** a partir de grandes volumes de dados.

Estudar análise sintática neste ponto do curso é essencial para compreender:

- o que os modelos modernos deixaram de explicitar,
- o que eles passaram a aprender de forma implícita,
- e por que conceitos sintáticos continuam relevantes, mesmo em abordagens aparentemente “agnósticas à linguística”.

Representações formais: o mapa da sentença **SLIDE 8**

Para que um algoritmo possa “enxergar” a estrutura de uma frase, é necessário representá-la de forma explícita. No PLN, isso é feito por meio de **representações sintáticas formais**, que funcionam como mapas da organização gramatical da sentença.

Nesta aula, focaremos nas duas famílias de representações que dominaram — e ainda dominam — a literatura:

- **Árvores de Constituintes** **SLIDE 8**

Enfatizam a hierarquia e a composição da frase em unidades maiores (sintagmas).

- **Grafos de Dependência** **SLIDE 8**

Enfatizam as relações diretas entre palavras e os vínculos funcionais entre núcleos e dependentes.

Essas duas abordagens oferecem **lentes diferentes para observar a mesma frase**, e compreender suas diferenças é fundamental para entender tanto o PLN clássico quanto o moderno.

Checkpoint de aprendizagem

Antes de avançarmos para os detalhes técnicos, reflita:

Se um modelo de Word Embeddings (Aula 3) indica que “bom” e “ótimo” são semanticamente próximos,

o que a Análise Sintática (Aula 4) revela sobre a relação entre “aluno” e “estudou” em uma frase?

Essa transição — do significado das palavras para as **relações entre elas** — é exatamente o foco desta aula e o ponto de partida para tudo o que vem a seguir.

ii. Representações Sintáticas – Constituintes vs. Dependências

Duas lentes para a mesma frase

No capítulo anterior, estabelecemos que o significado de uma sentença não emerge apenas das palavras que a compõem, mas da **estrutura que organiza essas palavras**. Uma vez reconhecida a importância da sintaxe, surge uma nova questão fundamental no PLN:

Como representar formalmente a estrutura gramatical de uma sentença de modo que algoritmos possam operá-la?

Para responder a essa pergunta, o PLN desenvolveu diferentes formas de representação sintática. Historicamente, duas grandes famílias se consolidaram como centrais:

1. Árvores de Constituintes
2. Grafos de Dependência

Ambas descrevem a organização interna das sentenças, mas o fazem a partir de **pressupostos linguísticos distintos** e com **objetivos computacionais diferentes**. Entender essas diferenças é essencial para compreender tanto o PLN clássico quanto suas transformações modernas.

Para ilustrar os conceitos ao longo deste capítulo, utilizaremos a seguinte sentença-exemplo:

O aluno leu o livro.

1. Árvores de Constituintes (Sintagmas) **SLIDE 9**

Ideia central

A análise por constituintes tem origem na tradição da gramática gerativa clássica. Nessa abordagem, a sentença é vista como uma **estrutura hierárquica**, composta por unidades intermediárias chamadas **constituintes** ou **sintagmas**.

A ideia fundamental é que:

- palavras se agrupam em unidades maiores;
- essas unidades se combinam recursivamente;
- a estrutura da frase pode ser representada como uma **árvore**.

Os constituintes mais comuns incluem:

- Sintagma Nominal (SN)
- Sintagma Verbal (SV)
- Sintagma Preposicional (SP)

Exemplo conceitual

Considere a sentença: **SLIDE 9**

O aluno leu o livro.

Uma análise por constituintes identifica:

- um **Sintagma Nominal (SN)**: *O aluno*
- um **Sintagma Verbal (SV)**: *leu o livro*
- dentro do SV, outro **Sintagma Nominal**: *o livro*


De forma esquemática:

[SN: O aluno] + [SV: leu [SN: o livro]]

O foco dessa representação está na **composição da frase**, isto é, em como unidades menores se combinam para formar unidades maiores.

Exemplo 1 — Árvore de Constituintes

A análise de constituintes mostra a **hierarquia da frase em sintagmas**.



Interpretação

- **S** → sentença
- **SN** → sintagma nominal (sujeito)
- **SV** → sintagma verbal

Estrutura:

[SN O aluno] + [SV leu [SN o livro]]

Vantagens das árvores de constituintes **SLIDE 10**

Do ponto de vista linguístico e didático, essa abordagem oferece vantagens importantes:

- torna explícita a **hierarquia sintática** da sentença;

- reflete diretamente conceitos da linguística teórica clássica;
- facilita a análise de fenômenos como **recursividade** e **ambiguidade estrutural**.

Por essas razões, árvores de constituintes foram amplamente utilizadas nos primeiros sistemas de PLN e em corpora linguísticos anotados manualmente.

Limitações práticas SLIDE 11

Apesar de sua expressividade, essa abordagem apresenta limitações relevantes no contexto computacional:

- **alta complexidade estrutural**, com árvores profundas;
- **alto custo de anotação manual**;
- dificuldade de adaptação a línguas com ordem flexível das palavras;
- menor integração direta com algoritmos estatísticos simples.

Essas limitações motivaram o surgimento de representações mais enxutas e diretamente orientadas às relações entre palavras.

2. Grafos de Dependência (Relações Funcionais) SLIDE 12

Ideia central

A análise de dependências parte de um pressuposto diferente. Em vez de agrupar palavras em sintagmas, ela se concentra nas **relações diretas entre palavras individuais**.

Nesse modelo:

- cada palavra está ligada a outra por uma relação sintática;
- existe uma palavra central, chamada **núcleo** (*head*);
- as relações são rotuladas de acordo com sua função gramatical.

O resultado é uma estrutura em forma de **grafo direcionado**, que na prática costuma assumir a forma de uma árvore.

Exemplo conceitual) SLIDE 13

Na sentença:

O aluno leu o livro.

A análise de dependências identifica:

- **leu** como o núcleo da sentença;
- **aluno** como sujeito de *leu*;
- **livro** como objeto de *leu*;
- determinantes ligados diretamente aos substantivos correspondentes.

De forma simplificada:


- *leu* → (**nsubj**) → *aluno*

- *leu* → (**obj**) → *livro*

Aqui, o foco deixa de ser a composição de grupos e passa a ser **quem depende de quem** na frase.

Exemplo 2 — Grafo de Dependência

A análise de dependência mostra **relações diretas entre palavras**.



Relações sintáticas

Palavra	Relação	Dependência
aluno	sujeito	leu
livro	objeto	leu
O	determinante	aluno
o	determinante	livro

✓ Vantagens da análise de dependências **SLIDE 14**

A análise de dependências tornou-se predominante no PLN moderno por apresentar vantagens práticas claras:

- representação mais simples e compacta;
- alinhamento direto com relações semânticas básicas (*quem fez o quê*);
- maior robustez para línguas com ordem flexível;
- integração eficiente com modelos estatísticos e neurais.

Por essas razões, bibliotecas modernas de PLN, como o spaCy, adotam essa representação como padrão.

Limitações

Apesar de suas vantagens, a análise de dependências também possui limitações:

- a hierarquia de constituintes não é explicitada diretamente;
- certas generalizações linguísticas ficam menos visíveis;
- a interpretação depende fortemente da definição do núcleo.

Isso reforça que nenhuma das duas abordagens é superior em termos absolutos — cada uma privilegia aspectos distintos da estrutura sintática.

Comparação conceitual

De forma resumida:

- Árvores de Constituintes enfatizam:
 - hierarquia e composição,
 - unidades intermediárias,
 - proximidade com teorias linguísticas clássicas.
- Análise de Dependências enfatiza:
 - relações diretas entre palavras,
 - simplicidade estrutural,
 - aplicabilidade computacional.

Essa diferença reflete uma tensão histórica no PLN entre fidelidade linguística e viabilidade computacional em larga escala.

Checkpoint de aprendizagem

Reflita sobre a frase:

O cientista viu a estrela com o telescópio.

- O sintagma “*com o telescópio*” se liga a *ver* ou a *estrela*?
- Como essa ambiguidade apareceria:
 - em uma árvore de constituintes?
 - em um grafo de dependências?

Essa ambiguidade estrutural ilustra por que representar sintaxe não é apenas um exercício teórico, mas um desafio central para sistemas automáticos.

iii. Parsing – O Processo de Análise Sintática Automática **SLIDE 15**

O que é um parser?

Nos capítulos anteriores, vimos **por que** a estrutura sintática é essencial para o significado (Capítulo 1) e **como** essa estrutura pode ser representada formalmente por meio de árvores de constituintes e grafos de dependência (Capítulo 2).

Resta agora uma pergunta crucial:

Como ensinar o computador a construir automaticamente essas estruturas a partir de uma frase?

A resposta a essa pergunta está no **parsing sintático**.

No contexto do PLN, um **parser** (ou analisador sintático) é um algoritmo que:

- recebe uma sequência de tokens (uma frase);
- analisa suas possíveis organizações gramaticais;
- produz como saída uma **representação sintática estruturada**, seja ela:
 - uma árvore de constituintes, ou
 - um grafo de dependências.

Se a estrutura é o mapa da sentença, o parser é o **cartógrafo** responsável por desenhá-lo.

Por que parsing é um problema difícil?

À primeira vista, pode parecer que a análise sintática seja apenas a aplicação mecânica de regras gramaticais. No entanto, a linguagem humana apresenta uma característica que torna o parsing um dos maiores desafios do PLN: **ambiguidade estrutural**. (Ambiguidade estrutural acontece quando **uma frase pode ter mais de uma interpretação**) Diferentemente de linguagens de programação, em que cada instrução possui uma interpretação única, frases em língua natural frequentemente admitem **mais de uma estrutura gramatical plausível**.

O desafio da ambiguidade sintática **SLIDE 16**

Considere a frase:

O aluno viu o professor com o telescópio.

Essa frase admite, pelo menos, duas interpretações estruturais:

- Anexação ao verbo
O telescópio foi o instrumento usado para ver.
(*O aluno usou o telescópio.*)
- Anexação ao substantivo
O telescópio pertence ao professor.
(*O professor estava com o telescópio.*)

Do ponto de vista computacional, ambas as estruturas são gramaticalmente válidas. O parser precisa, portanto, **escolher a estrutura mais provável**, mesmo sem acesso direto ao “significado real” pretendido pelo falante. Esse problema ilustra por que parsing não é apenas uma questão de regras, mas de **decisão sob incerteza**.

Como parsers tomam decisões?

Historicamente, diferentes estratégias foram adotadas para resolver o problema do parsing. De forma simplificada, podemos agrupá-las em duas grandes abordagens.

Parsers baseados em regras (PLN clássico) **SLIDE 17**

Nos sistemas clássicos de PLN, o parsing era realizado com base em:

- gramáticas formais explícitas;

- regras linguísticas cuidadosamente definidas;
- algoritmos determinísticos ou quase determinísticos.

Esses parsers:

- produziam estruturas linguisticamente bem fundamentadas;
- eram interpretáveis e teoricamente elegantes;
- mas exigiam alto custo de desenvolvimento e manutenção.

Além disso, eram pouco robustos a:

- ruído textual;
- variações linguísticas;
- domínios não previstos pela gramática.



Parsers baseados em aprendizado estatístico **SLIDE 17**

Com a disponibilidade de grandes corpora anotados (*treebanks*), o PLN passou a adotar parsers que **aprendem a tomar decisões a partir de dados**.

Nessa abordagem:

- o parser observa milhares ou milhões de exemplos de frases anotadas;
- aprende padrões estatísticos de estrutura;
- passa a atribuir probabilidades às possíveis análises.

Diante de uma frase ambígua, o parser escolhe:

a estrutura mais provável dado o que aprendeu com os dados.

Essa mudança marcou uma transição decisiva do PLN baseado em regras para o PLN baseado em aprendizado.



Parsing de dependências baseado em transições **SLIDE 18**

Atualmente, a forma mais comum de parsing sintático em sistemas práticos é o **parsing de dependências baseado em transições**, utilizado por bibliotecas modernas como o spaCy.



Ideia geral

Esse tipo de parser simula um processo incremental de leitura da frase, geralmente da esquerda para a direita, utilizando duas estruturas principais:

- **fila (buffer)**: contém as palavras ainda não processadas;
- **pilha (stack)**: armazena palavras parcialmente analisadas.

A cada passo, o parser decide:

- mover palavras entre a fila e a pilha;
- criar uma relação de dependência entre duas palavras;
- rotular essa relação (ex.: sujeito, objeto, modificador).

Essas decisões são tomadas com base em modelos estatísticos ou neurais treinados previamente.

Exemplo conceitual

Para a frase:

O aluno leu o livro.

O parser realiza, passo a passo:

- a identificação de *leu* como núcleo da sentença;
- a ligação de *aluno* como sujeito;
- a ligação de *livro* como objeto;
- a associação de determinantes aos substantivos correspondentes.

Ao final do processo, obtém-se um grafo de dependências completo, representando a estrutura sintática da frase.

Checkpoint de aprendizagem

Refleta:

Se um parser precisa escolher entre duas estruturas possíveis,

o que ele utiliza para tomar essa decisão?

A resposta — dados, probabilidades e contexto — antecipa diretamente a lógica dos modelos modernos baseados em atenção.

Da sintaxe explícita à sintaxe implícita

Este capítulo ocupa um papel estratégico na disciplina, pois evidencia uma mudança conceitual profunda.

No **PLN clássico**:

- o parser era um componente isolado e indispensável;
- sem análise sintática explícita, o sistema não avançava para tarefas semânticas.

No **PLN moderno**, especialmente com modelos baseados em Transformers:

- raramente treinamos parsers explícitos para tarefas como classificação ou tradução;
- ainda assim, os modelos capturam dependências sintáticas complexas.

O que mudou não foi a importância da sintaxe, mas **a forma como ela é incorporada**:

- antes, como uma estrutura explícita construída por regras;
- agora, como uma regularidade **aprendida implicitamente** nas camadas internas do modelo.

Por que ainda estudar parsing?

Diante desse cenário, surge uma pergunta legítima:

Se os modelos modernos aprendem sintaxe sozinhos, por que ainda estudar parsing?

Há pelo menos três razões fundamentais:

- Interpretabilidade

Estruturas sintáticas explícitas ajudam a entender e auditar decisões de modelos complexos.

- Extração de informação estruturada

Muitas aplicações exigem respostas do tipo *quem fez o quê*, algo diretamente apoiado por grafos de dependência.

- Fundamentação conceitual

Compreender parsing permite entender *o que* os modelos modernos estão aprendendo implicitamente.

iv. Aplicações e a Extração de Relações Sintáticas **SLIDE 19**

Além da classificação: por que extrair relações?

Até este ponto do curso, grande parte dos exemplos envolveu tarefas de **classificação**, como análise de sentimentos ou identificação de tópicos. Nessas tarefas, o objetivo principal é atribuir um rótulo global a um texto ou sentença. No entanto, muitas aplicações reais de PLN exigem algo diferente:

não apenas classificar textos, mas **extrair informações estruturadas** a partir deles.

Em outras palavras, o sistema não deve apenas “entender sobre o que o texto fala”, mas responder perguntas do tipo:

- Quem realizou uma ação?
- O que foi afetado por essa ação?
- Quando, como e em que condições ela ocorreu?

É nesse contexto que a análise sintática — especialmente a análise de dependências — revela seu valor prático mais imediato.

Extração de relações: do texto ao conhecimento estruturado **SLIDE 20**

Considere a seguinte frase:

A empresa X adquiriu a startup Y por 10 milhões de reais.

Um sistema de PLN voltado apenas à classificação poderia concluir corretamente que o texto trata de negócios ou aquisições. No entanto, para aplicações reais, isso é insuficiente.

Um sistema de **extração de relações** precisa identificar explicitamente:

-   Quem realizou a ação? → *empresa X*
-  O que foi adquirido? → *startup Y*
-  Qual foi o valor? → *10 milhões de reais*

Essas informações, uma vez extraídas, podem ser armazenadas em bancos de dados, grafos de conhecimento ou sistemas de consulta estruturada.

A análise de dependências fornece exatamente o tipo de estrutura necessária para esse processo.

 O papel da sintaxe na extração de relações

A análise sintática atua como uma **ponte entre texto e estrutura de dados**. Ao explicitar relações como sujeito, objeto e modificadores, ela permite que o sistema:

- identifique eventos centrais (geralmente associados a verbos);
- reconheça participantes do evento;
- associe corretamente atributos, quantificadores e circunstâncias.

Sem essa estrutura, a extração de relações torna-se frágil e altamente dependente de heurísticas superficiais.

 Exemplo prático: quem fez o quê?

Considere a frase:

O pesquisador que orientou o aluno publicou o artigo.

A estrutura linear da frase é complexa, mas a análise de dependências permite identificar corretamente que:

-  o núcleo do evento principal é *publicou*;
-  *pesquisador* é o sujeito de *publicou*;
-  *artigo* é o objeto de *publicou*;
- a oração *que orientou o aluno* é apenas um modificador do sujeito.

Essa distinção é fundamental para evitar erros como atribuir a ação de *publicar* ao aluno, algo que um modelo superficial poderia fazer.

 Sintaxe como apoio à desambiguação semântica

Além da extração de relações, a análise sintática desempenha um papel crucial na **desambiguação semântica**.

Considere os exemplos:

- *O voto do deputado foi decisivo.*
- *Eu voto consciente.*

A palavra *voto* aparece nos dois casos, mas exerce funções sintáticas distintas:

- no primeiro caso, é um **substantivo**;
- no segundo, é um **verbo**.

A análise sintática — frequentemente em conjunto com a rotulação morfossintática (*Part-of-Speech Tagging*) — permite diferenciar esses usos, algo que embeddings de palavras isoladas têm dificuldade em fazer.

 Checkpoint de aprendizagem

Reflita:

Se um modelo moderno consegue capturar relações como sujeito e objeto sem construir explicitamente um grafo de dependências,

em que situações ainda faz sentido extrair essas estruturas de forma explícita?

Essa pergunta aponta para aplicações em que **interpretabilidade, controle e estrutura explícita** são requisitos, não opcionais.



Notebook da Aula 4 – Análise Sintática com spaCy

No notebook associado a esta aula, você irá:

- 🔍 visualizar grafos reais de dependência sintática;
- 🧠 identificar núcleo, sujeito, objeto e modificadores em frases reais;
- ⚠️ observar como parsers lidam com **ambiguidade sintática**;
- 🎯 compreender como relações estruturais podem ser extraídas automaticamente;
- 🤖 estabelecer uma conexão explícita entre **sintaxe clássica** e **PLN moderno**.

A atividade foi estruturada em etapas guiadas, com perguntas de reflexão a cada exemplo, de modo que o foco esteja na **interpretação linguística das estruturas**, e não na implementação técnica do parser.



Orientação

Durante a execução do notebook, você deve manter em mente as seguintes questões:

- Qual palavra atua como núcleo da sentença?
- Como o parser representa a relação entre sujeito, verbo e objeto?
- De que forma modificadores alteram a interpretação da frase?
- Em casos ambíguos, **qual estrutura o parser escolhe e por quê?**

Essas perguntas são as mesmas discutidas teoricamente ao longo da aula e constituem o elo entre **análise sintática explícita** e **aprendizado implícito de estrutura**, que será aprofundado na próxima aula.