

Objetivos da aula:

- Compreender a motivação conceitual que levou ao surgimento dos Transformers e sua relação com os limites do PLN clássico.
- Explicar a ideia central do mecanismo de atenção e como ele contribui para a modelagem de dependências sintáticas e semânticas de forma implícita, sem o uso de regras gramaticais explícitas.
- Descrever, em nível conceitual, a arquitetura Transformer, identificando seus principais componentes e suas funções.
- Compreender o que são modelos de linguagem pré-treinados, como são treinados e por que generalizam bem para múltiplas tarefas.
- Reconhecer vantagens e limitações técnicas, linguísticas e introdutórias associadas ao uso desses modelos, especialmente no que diz respeito à interpretabilidade.
- Estabelecer uma conexão crítica entre a análise sintática explícita estudada na Aula 4 e a aprendizagem implícita de estrutura em modelos baseados em atenção.
- Desenvolver uma visão crítica sobre quando, como e por que utilizar modelos de linguagem modernos em aplicações reais de PLN.

Índice:

- i. Da Sintaxe Explícita à Atenção – O Salto Tecnológico
- ii. O Mecanismo de Atenção – A "Sintaxe Dinâmica"
- iii. Modelos de Linguagem Pré-Treinados: Aprender Antes de Usar

i. Da Sintaxe Explícita à Atenção – O Salto Tecnológico **Contextualização SLIDE 5 e 6**

Na Aula 4, vimos que a linguagem possui uma espécie de “*planta arquitetônica*”. Utilizamos ferramentas capazes de construir grafos de dependência sintática e de identificar, com precisão, elementos como sujeito, objeto e o núcleo sintático da frase (*ROOT*).

Embora esse processo — conhecido como *parsing sintático* — seja extremamente útil para tarefas de extração de informação, ele apresenta dois desafios importantes quando aplicado a contextos reais de uso da linguagem:

- Rigidez: depende de modelos treinados explicitamente para uma gramática específica, o que limita sua adaptação a variações linguísticas.
- Ambiguidade: como observado no exercício clássico do “telescópio”, nem sempre é possível determinar corretamente qual relação sintática deve ser estabelecida sem acesso a um contexto mais amplo.

 A Grande Mudança: Da Flecha para o Peso SLIDE 7

A pergunta central que orienta a Aula 5 é a seguinte:

E se não fosse necessário “ensinar” regras gramaticais explícitas ao computador?

Nos modelos baseados em Transformers, que estudaremos a partir de agora, não são injetadas regras formais de sujeito, objeto ou modificador. Em vez disso, o modelo utiliza um mecanismo denominado Self-Attention (*autoatenção*).

Podemos contrastar as abordagens da seguinte forma:

- Aula 4 (Sintaxe): definimos conexões binárias e discretas (por exemplo, “com o telescópio” liga-se ou não ao verbo “viu”).
- Aula 5 (Atenção): o modelo calcula valores numéricos contínuos (pesos) que indicam o grau de relevância de uma palavra para a interpretação de outra.

A ideia central é que, ao “prestar atenção” simultaneamente às palavras mais relevantes do contexto, o modelo passa a **aprender padrões sintáticos de forma implícita**, estatística e significativamente mais flexível do que nos métodos baseados em regras.



O Fim do Pipeline Rígido SLIDE 8

Historicamente, sistemas clássicos de PLN eram organizados em *pipelines* sequenciais, como no caso de tradutores automáticos:

1. Limpeza do texto
2. Etiquetagem morfosintática
3. Análise sintática
4. Tradução

Com a arquitetura Transformer, esse pipeline é essencialmente **achatado**. O modelo recebe o texto bruto e, por meio de múltiplas camadas de atenção, resolve simultaneamente aspectos semânticos (Aula 3) e sintáticos (Aula 4), sem a necessidade de etapas intermediárias explícitas.



Por que ainda estudamos a Aula 4? SLIDE 9

Uma pergunta natural neste ponto é:

se os Transformers aprendem a estrutura sozinhos, por que estudar análise sintática explícita?

A resposta é **interpretabilidade**.

Os modelos atuais de linguagem são, em grande medida, **caixas-pretas**. Para investigar se um modelo está cometendo erros sistemáticos, reproduzindo vieses ou tomando decisões por razões inadequadas, recorreremos às ferramentas clássicas de análise sintática estudadas na Aula 4, que permitem **auditar e interpretar** o comportamento da atenção “por baixo do capô”.



Checkpoint de aprendizagem

No próximo capítulo, abriremos o “motor” do Transformer para compreender como o mecanismo de atenção é calculado do ponto de vista matemático.

Prepare-se: aquilo que ferramentas como o spaCy realizavam por meio de regras explícitas, os Transformers passam a executar por meio de **álgebra linear, vetores e matrizes**.

O Mecanismo de Atenção – A "Sintaxe Dinâmica" SLIDE 10



O que é Atenção?

Na Aula 4, estudamos como relações sintáticas — como a ligação entre sujeito e verbo — são estabelecidas a partir de regras gramaticais explícitas. No entanto, o processamento humano da linguagem não ocorre apenas por meio da aplicação consciente dessas regras. Ao compreender um texto, o leitor humano **focaliza seletivamente partes da frase** que são mais relevantes para a construção do sentido.

O mecanismo de **Self-Attention** (*autoatenção*) permite que modelos computacionais realizem um procedimento análogo. Para cada palavra processada, o modelo considera **todas as demais palavras da sequência** e determina quais delas são mais importantes para a interpretação daquela palavra específica dentro do contexto.



Query (Consulta), Key (Chave) e Value (Valor) SLIDE 11

Para operacionalizar matematicamente o cálculo da atenção, os Transformers utilizam uma analogia inspirada em sistemas de busca e recuperação de informação:

- **Query (Q):** representa a palavra em foco, isto é, *o que está sendo buscado*;
- **Key (K):** representa as palavras disponíveis no contexto, isto é, *o que pode ser comparado*;
- **Value (V):** representa a informação semântica associada a cada palavra, isto é, *o conteúdo que será agregado*.

O modelo calcula a similaridade entre a *Query* e cada *Key*. Quanto maior essa similaridade, maior será o peso atribuído ao *Value* correspondente. O resultado é uma combinação ponderada das informações relevantes para a palavra analisada.



Dependência Sintática (Aula 4) vs. Atenção (Aula 5) SLIDE 12

A principal diferença conceitual e prática entre as duas abordagens pode ser resumida da seguinte forma:

- **Aula 4 (análise sintática clássica):** as relações são **discretas, binárias e rotuladas**. Uma palavra está ou não ligada a outra por um tipo específico de dependência.
- **Aula 5 (modelos baseados em atenção):** as relações são **contínuas e probabilísticas**. Uma palavra pode receber diferentes graus de atenção de múltiplas outras palavras simultaneamente.

Por exemplo, o modelo pode atribuir 70% de atenção a um verbo e 30% a um substantivo, capturando nuances sintáticas e semânticas que frequentemente escapam a grafos rígidos de dependência.

 Multi-Head Attention: Múltiplas Perspectivas em Paralelo SLIDE 13

Os Transformers empregam o mecanismo de Multi-Head Attention (*atenção de múltiplas cabeças*). Em termos conceituais, isso equivale a permitir que o modelo realize **várias análises paralelas da mesma frase**, cada uma com um foco distinto.

De forma ilustrativa:

- Uma cabeça pode priorizar relações sintáticas (por exemplo, identificar o sujeito de um verbo);
- Outra pode enfatizar relações semânticas (como similaridade de significado);
- Uma terceira pode se especializar em relações referenciais (como a resolução de pronomes).

A saída final do modelo resulta da combinação dessas diferentes “visões”, o que explica a expressiva capacidade dos Transformers de modelar linguagem natural de forma rica e contextualizada.

 Conexão com o Notebook Prático SLIDE 14

Nesta aula, a compreensão do mecanismo de atenção será consolidada por meio de um notebook prático, no qual utilizaremos um modelo Transformer pré-treinado (BERT) para analisar como a atenção é distribuída entre os tokens de uma frase.

Diferentemente da Aula 4, não construiremos árvores sintáticas explícitas. Em vez disso, visualizaremos mapas de calor (heatmaps) que representam os pesos de atenção calculados pelo modelo em diferentes camadas e cabeças. É importante destacar que esses mapas **não devem ser interpretados como grafos sintáticos ou explicações diretas do significado**, mas como visualizações do processo interno de combinação de informação realizado pelo modelo.

O objetivo do notebook não é “encontrar” uma regra gramatical no mapa de atenção, mas compreender como padrões linguísticos podem emergir de forma distribuída a partir da interação entre múltiplas cabeças e camadas.

 Observação Importante sobre Interpretabilidade SLIDE 15

Embora os mapas de atenção sejam ferramentas úteis para exploração e intuição, eles não constituem explicações linguísticas completas.

Muitas cabeças exibem padrões locais, difusos ou focados no próprio token, especialmente em camadas finais. Essa limitação de interpretabilidade é uma característica estrutural dos Transformers e reforça a importância de combinar modelos neurais com ferramentas simbólicas, como a análise sintática explícita estudada na Aula 4.

 Checkpoint de aprendizagem

Considere a frase:

“O banco estava fechado porque era feriado.”

A palavra *banco* é semanticamente ambígua.

- Na Aula 4, essa ambiguidade pode ser tratada por meio de relações sintáticas explícitas e regras linguísticas.

- Na Aula 5, a desambiguação ocorre de forma implícita e distribuída.

No notebook prático, observaremos como o modelo utiliza o contexto global da frase para construir uma representação coerente, ainda que essa desambiguação **não apareça como uma ligação direta e isolada nos mapas de atenção**.

ii. Modelos de Linguagem Pré-treinados – Aprender antes de Usar **SLIDE 16**



O Paradigma do Pré-treinamento

Até a Aula 4, estivemos majoritariamente acostumados a duas estratégias: utilizar ferramentas prontas — como modelos estatísticos já treinados — ou treinar modelos específicos do zero para cada tarefa. Com o advento dos Transformers, esse paradigma se altera de forma significativa.

Nos modelos modernos de linguagem, o treinamento ocorre em duas etapas distintas. Primeiramente, o modelo passa por um **pré-treinamento em larga escala**, no qual é exposto a volumes massivos de texto. Nessa fase, ele aprende regularidades gerais da língua: padrões sintáticos, relações semânticas e estruturas discursivas. Somente após esse processo o modelo é **adaptado (fine-tuned)** para tarefas específicas, como análise de sentimentos, classificação de textos ou reconhecimento de entidades nomeadas.

Esse novo fluxo explica por que tais modelos conseguem generalizar bem mesmo em cenários com poucos dados anotados.



BERT: O Modelo do Contexto Bidirecional **SLIDE 17**

O BERT (*Bidirectional Encoder Representations from Transformers*), desenvolvido pelo Google, é um exemplo paradigmático de modelo focado na **compreensão profunda do contexto linguístico**. Diferentemente de modelos anteriores, o BERT analisa simultaneamente o que vem antes e depois de cada palavra, construindo representações contextuais bidirecionais.

Seu principal método de treinamento é o Masked Language Modeling. Nesse procedimento, algumas palavras de uma frase são ocultadas, e o modelo deve prever quais termos foram removidos.

Essa tarefa força o modelo a explorar relações sintáticas e semânticas complexas. Por exemplo, na frase:

“O [MÁSCARA] comeu o queijo.”

o modelo precisa inferir, a partir da estrutura da frase, que a palavra ausente deve ser um substantivo com função de sujeito.

Do ponto de vista conceitual, isso estabelece uma conexão direta com a Aula 4: embora o BERT não utilize regras explícitas de sintaxe, ele **internaliza padrões estruturais** que desempenham função análoga às dependências sintáticas tradicionais.

Uso prático:

O BERT é especialmente adequado para tarefas de compreensão textual, como classificação de sentenças, busca semântica e reconhecimento de entidades.

GPT: O Modelo da Geração Unidirecional SLIDE 18

Enquanto o BERT é otimizado para compreensão, o GPT (*Generative Pre-trained Transformer*), desenvolvido pela OpenAI, é projetado principalmente para **geração de texto**.

Seu treinamento baseia-se na predição da próxima palavra em uma sequência. O modelo processa o texto da esquerda para a direita e aprende a estimar a probabilidade do próximo token dado o histórico anterior. Por exemplo, ao ler:

“O aluno estudou para a...”

o modelo atribui alta probabilidade à continuação *“prova”*.

Do ponto de vista da atenção, a diferença fundamental em relação ao BERT é que o GPT utiliza **atenção causal**, ou seja, ele só pode acessar palavras que já foram apresentadas na sequência.

Uso prático:

Esse tipo de modelo constitui a base de sistemas de geração automática de texto, assistentes conversacionais e modelos de escrita criativa.

Onde entra a Sintaxe nesse Novo Paradigma?

Em modelos como BERT e GPT, a sintaxe não é codificada como um conjunto de regras explícitas, mas emerge como um **padrão estatístico aprendido a partir dos dados**.

Podemos contrastar os dois paradigmas da seguinte forma:

Aspecto	Análise Sintática (Aula 4)	Modelos Pré-treinados (Aula 5)
Representação	Árvores e grafos discretos	Vetores contextuais contínuos
Tratamento da ambiguidade	Regras e heurísticas do parser	Contexto global da sequência
Origem do conhecimento	Definido por linguistas	Aprendido por exposição massiva

Essa mudança não elimina a relevância da sintaxe tradicional, mas redefine seu papel dentro do ecossistema do PLN moderno.

Checkpoint de Aprendizagem

Considere a tarefa de verificar se um contrato foi assinado corretamente.

- Uma abordagem baseada na Aula 4 poderia garantir, por meio de análise sintática, que o sujeito “Empresa X” está corretamente ligado ao verbo “assinar”.
- Uma abordagem baseada na Aula 5 utilizaria um modelo como o BERT para classificar se o texto expressa, de modo global, uma situação de conformidade legal.

Na prática contemporânea, a estratégia mais robusta combina ambos os enfoques: utilizamos modelos pré-treinados para tomar decisões e ferramentas sintáticas para **interpretar e justificar** essas decisões.