

Objetivos da aula:

- Distinguir análise semântica de análise lexical e sintática no contexto do PLN.
- Compreender o conceito de referência, relacionando palavras a entidades e eventos do mundo real.
- Explicar o papel do Reconhecimento de Entidades Nomeadas (NER) na interpretação semântica.
- Reconhecer limites e vantagens de taxonomias semânticas em tarefas de NER.
- Interpretar o esquema BIO, identificando entidades multi-token.
- Analisar ambiguidades semânticas, como polissemia e metonímia.
- Compreender os fundamentos da Extração de Relações entre entidades.
- Diferenciar relações e eventos em modelos semânticos de PLN.
- Entender a integração de NER, relações e eventos em um pipeline semântico.

Índice:

- i. O Salto do "Como" para o "O Quê"
- ii. Reconhecimento de Entidades Nomeadas (NER): a Identificação do Referente
- iii. Extração de Relações e Eventos: Conectando o Mundo

i. O Salto do "Como" para o "O Quê"**■ Sintaxe não é semântica: quando a estrutura não basta SLIDE 4**

Nas aulas anteriores, em especial na Aula 4 (Análise Sintática) e na Aula 5 (Transformers), aprendemos **como** o computador organiza e processa frases:

- identifica classes gramaticais;
- constrói árvores de dependência;
- modela relações estatísticas entre palavras.

Entretanto, existe um limite claro para esse tipo de processamento. Um sistema pode analisar perfeitamente a **forma** de uma frase sem compreender absolutamente nada sobre o seu **significado**.

O exemplo clássico de Noam Chomsky ilustra esse problema:

"Ideias verdes incolores dormem furiosamente."

Do ponto de vista sintático, a frase é impecável. Há sujeito, predicados, concordância e ordem gramatical correta. Contudo, do ponto de vista semântico, ela não se ancora em nenhum estado possível do mundo real. Não há "ideias" que sejam simultaneamente verdes e incolores, nem entidades abstratas que "durmam".

Noam Chomsky foi um dos maiores estudiosos da linguagem. Ele mostrou que uma frase pode estar correta na gramática, mas ainda assim não fazer sentido. Por isso ele é muito importante para entender a diferença entre sintaxe e semântica no PLN.

Esse exemplo revela um ponto central desta aula:

A **sintaxe** descreve a estrutura do texto; a **semântica** tenta explicar o que o texto diz sobre o mundo.

No notebook desta aula, esse salto conceitual ficará evidente quando percebermos que **uma árvore sintática correta não garante uma interpretação útil**, enquanto uma decisão semântica incorreta compromete toda a extração de informação.

🌀 O Problema da referência: palavras não são coisas **SLIDE 5**

O principal desafio da análise semântica em PLN é o **problema da referência**:

palavras não são objetos do mundo — elas **apontam** para objetos, conceitos, eventos ou entidades.

Considere a palavra:

Apple

Na análise sintática, pouco importa se essa palavra se refere a uma fruta ou a uma empresa. Ela pode ser sujeito, objeto ou complemento em ambos os casos.

Na análise semântica, essa distinção é crucial:

- “Apple lançou um novo produto.” → entidade corporativa
- “Apple é rica em fibras.” → entidade biológica

Sem resolver esse problema, o sistema de PLN atua apenas como um **manipulador de símbolos**.

Ao resolvê-lo, o sistema passa a atuar como um **extrator de fatos**.

É exatamente esse tipo de decisão que será tomada no notebook quando o modelo de **Reconhecimento de Entidades Nomeadas (NER)** precisar escolher, com base no contexto, **qual entidade do mundo real está sendo mencionada**.

🧠 O triângulo semântico aplicado ao PLN **SLIDE 6**

Uma forma clássica de compreender a interpretação semântica é por meio do **triângulo semântico**, que no contexto do PLN pode ser descrito da seguinte forma:

- **Símbolo**: a palavra ou sequência de tokens no texto
(ex.: “Paris”)
- **Conceito**: a representação interna aprendida pelo modelo
(vetores de embedding contextualizados) Vetores de embedding contextualizados são representações numéricas das palavras que mudam de acordo com o contexto da frase.
- **Referente**: o objeto ou entidade no mundo real [O referente é aquilo que a palavra está apontando na realidade.]
(a cidade, capital da França)

Os modelos baseados em Transformers, que utilizamos no notebook, não “conhecem” diretamente o referente. O que eles fazem é **aproximar o conceito do símbolo correto a partir do contexto**, permitindo que etapas posteriores

— como NER (É uma técnica de **PLN (Processamento de Linguagem Natural)** usada para **identificar e classificar entidades importantes em um texto**) e extração de relações — façam essa ancoragem ao mundo.

Quando, no notebook, um token é classificado como LOC (localização), ORG (organização) ou PER (pessoa), estamos observando uma tentativa computacional de **fechar esse triângulo semântico**.

Por que a semântica é computacionalmente mais cara SLIDE 7

Diferentemente da análise sintática, que pode ser realizada olhando apenas para a estrutura da frase, a análise semântica frequentemente exige **conhecimento de mundo implícito**.

Considere:

- “O banco foi assaltado.”
- “O banco foi pintado de azul.”

A palavra “banco” é a mesma. A estrutura sintática é semelhante.

A interpretação correta, contudo, depende de sabermos que:

- instituições financeiras são assaltadas;
- objetos físicos são pintados.

Esse tipo de conhecimento não é codificado em regras simples. Ele emerge de grandes volumes de dados, sendo **internalizado estatisticamente** nos pesos dos modelos de linguagem.

No notebook desta aula, esse ponto se manifesta quando o modelo consegue:

- distinguir entidades com o mesmo nome;
- inferir relações plausíveis entre entidades;
- rejeitar interpretações semanticamente improváveis, mesmo que sintaticamente válidas.

Da estrutura à compreensão: preparando o pipeline semântico SLIDE 8

Este primeiro capítulo cumpre uma função essencial: **justificar por que precisamos ir além da sintaxe**.

A partir dele, a aula avança para ferramentas concretas que operacionalizam a semântica:

1. **Reconhecimento de Entidades Nomeadas (NER)**

→ identificar *quem* e *o quê* aparece no texto.

2. **Extração de Relações**

→ identificar *como* essas entidades se conectam.

3. **Extração de Eventos**

→ identificar *o que aconteceu, quando e onde*.

No notebook, essas etapas aparecerão como um **pipeline integrado**, no qual cada decisão semântica incorreta se propaga e compromete o resultado final. Essa dependência entre etapas é o que torna a análise semântica não apenas mais complexa, mas também **mais crítica** do ponto de vista computacional e aplicado.

ii. Reconhecimento de Entidades Nomeadas (Named Entity Recognition – NER): a Identificação do Referente

Do significado abstrato ao referente concreto

No capítulo anterior, estabelecemos que a análise semântica consiste em **mapear estruturas linguísticas para elementos do mundo real**. Esse mapeamento, contudo, não acontece de forma direta nem global. Ele é construído **progressivamente**, a partir de decisões locais tomadas sobre partes do texto.

O Reconhecimento de Entidades Nomeadas (NER) é a primeira e mais fundamental dessas decisões.

Enquanto a sintaxe responde à pergunta:

“Qual é a função gramatical desta palavra?”

o NER responde a uma pergunta qualitativamente diferente:

“Este trecho do texto se refere a uma entidade específica do mundo?”

No notebook da aula, isso se materializa quando um token deixa de ser apenas uma string e passa a ser interpretado como PESSOA, ORGANIZAÇÃO, LOCAL, DATA, entre outras categorias semânticas.

O que realmente está em jogo no NER

É comum confundir NER com uma simples tarefa de classificação lexical. Essa interpretação é equivocada.

Identificar que “João” é um substantivo próprio pertence ao domínio da **morfossintaxe**.

Identificar que “João” é uma **entidade do tipo PESSOA**, com potencial de agir, possuir, decidir ou sofrer ações, pertence ao domínio da **semântica**.

Quando o sistema identifica:

“Amazon anunciou novos investimentos.”

e classifica “Amazon” como ORG, ele está realizando uma **desambiguação semântica contextual**, descartando a interpretação geográfica (rio) em favor da interpretação corporativa.

Essa decisão é crítica porque:

- define **quais entidades podem participar de relações**;
- limita **quais eventos são semanticamente plausíveis**;
- condiciona todas as etapas seguintes do pipeline de Extração de Informação.

Um erro nesse ponto compromete toda a cadeia posterior.

Taxonomias: o compromisso entre simplicidade e significado **SLIDE 9**

Na prática, o NER opera com **conjuntos finitos de etiquetas**, também chamados de **taxonomias**. As mais tradicionais incluem categorias como:

- PER – Pessoa
- ORG – Organização
- LOC – Local

- DATE, TIME, MONEY, etc.

Essas categorias são **intencionalmente genéricas**. Elas não pretendem capturar toda a riqueza semântica do mundo, mas fornecer um **nível mínimo de ancoragem referencial**.

Contudo, do ponto de vista conceitual, é importante distinguir:

- **Taxonomias** → listas fechadas de rótulos;
- **Ontologias** → modelos ricos de conceitos e relações.

No notebook, trabalhamos com taxonomias porque:

- são computacionalmente viáveis;
- permitem treinamento supervisionado;
- servem como base para grafos de conhecimento posteriores.

Em aplicações de domínio específico (direito, medicina, finanças), essas taxonomias podem e devem ser refinadas para categorias semanticamente mais profundas, como JUIZ, RÉU, DOENÇA ou MEDICAMENTO.

BIO Tagging: quando a entidade não cabe em uma palavra

Um desafio essencial do NER é que **entidades raramente coincidem com tokens isolados**. A maioria das entidades relevantes é composta por múltiplas palavras.

Frase de exemplo:

“Fatec de Jacareí anunciou novas vagas.”

Aqui, a entidade é:

- **Fatec de Jacareí**

Ela **não é só um token (uma palavra)**, ela é formada por vários tokens:

- Fatec
- de
- Jacareí

 Ou seja:

- **1 entidade**
- **3 palavras (3 tokens)**

Para lidar com isso, utilizamos o esquema BIO (Beginning, Inside, Outside), que permite ao modelo identificar **fronteiras semânticas**, e não apenas classes.

Exemplo:

- B-ORG Fatec
- I-ORG de
- I-ORG Jacareí
- O anunciou

Essa representação resolve dois problemas fundamentais:

1. Permite tratar sequências de tokens como **uma única entidade semântica**
2. Evita que o modelo fragmente conceitos que, no mundo real, são indivisíveis

No notebook, essa codificação aparece de forma explícita nas saídas do modelo, e é fundamental que compreendamos que **não se trata de um detalhe técnico**, mas de uma decisão conceitual sobre **o que conta como uma unidade de significado**.

Ambiguidade semântica: quando o mundo escapa às etiquetas SLIDE 10

Mesmo com modelos avançados, o NER enfrenta desafios que não podem ser resolvidos apenas com regras.

Dois fenômenos são particularmente relevantes:

a) Polissemia de entidades

A mesma expressão pode referir-se a entidades distintas, dependendo do contexto:

- “O Rio de Janeiro continua lindo.” → Local
- “O Rio de Janeiro aprovou a nova lei.” → Entidade governamental

A decisão correta exige que o modelo considere **o verbo, o predicado e o contexto discursivo**, não apenas a forma da entidade.

b) Metonímia

Em muitos casos, um local é usado para representar uma instituição ou um grupo humano:

“Brasília decidiu aumentar os impostos.”

Sintaticamente, “Brasília” é um local.

Semanticamente, ela funciona como GOVERNO FEDERAL.

Modelos baseados em Transformers lidam melhor com esses casos porque a **atenção contextual** permite associar verbos como “decidir”, “aprovar” ou “determinar” a sujeitos institucionais, forçando a reinterpretar a entidade.

Desafios Semânticos no NER: Metonímia e Polissemia

A verdadeira interpretação semântica brilha onde as regras falham. Somos provocados a pensar nos seguintes casos:

1. **Metonímia:** “Brasília decidiu sobre os impostos.”
 - Sintaticamente, “Brasília” é um Local.
 - Semanticamente, neste contexto, ela funciona como uma ORGANIZAÇÃO (o Governo Federal).

2. **Polissemia de Entidade:** "*O Rio de Janeiro continua lindo*" (Local) vs. "*O Rio de Janeiro aprovou a nova lei*" (Entidade Política/Governo).

Modelos baseados em Transformers (Aula 5) são os primeiros a conseguir resolver esses problemas de forma elegante, pois a "Atenção" permite que o modelo perceba que o verbo "decidiu" ou "aprovou" exige um sujeito animado ou institucional, forçando a interpretação de "Brasília" ou "Rio" para além do sentido geográfico.

O custo do erro semântico

Na Aula 4, um erro sintático resultava, na pior hipótese, em:

- uma dependência mal posicionada;
- uma árvore incorreta, mas ainda interpretável.

Na Aula 6, um erro de NER representa algo mais grave:

um erro de compreensão do texto

Confundir uma organização com uma pessoa, ou um local com um evento, significa **ancorar o texto à realidade errada**. Em aplicações práticas — análise jurídica, mineração de notícias, chatbots ou sistemas de recomendação — esse tipo de erro tem impacto direto na confiabilidade do sistema.

Por isso, no notebook, a análise dos resultados de NER não deve ser apenas **quantitativa** (acurácia, F1), mas também **qualitativa**, observando:

- tipos recorrentes de erro;
- ambiguidade mal resolvida;
- dependência excessiva de padrões superficiais.

Preparando o terreno para relações e eventos

Ao final deste capítulo, alcançamos um ponto fundamental:

Entidades são os nós semânticos do texto.

Sem identificá-las corretamente, não é possível:

- extrair relações coerentes;
- modelar eventos completos;
- construir grafos de conhecimento confiáveis.

O próximo capítulo avançará exatamente nesse sentido, mostrando como **entidades isoladas passam a fazer sentido apenas quando conectadas**, dando origem à **Extração de Relações e Eventos** — o passo definitivo da análise semântica rumo à Descoberta de Conhecimento em Textos (KDT).

iii. Extração de Relações e Eventos: Conectando o Mundo **SLIDE 11**

Entidades isoladas não produzem conhecimento

Ao final do Capítulo 2, estabelecemos que as entidades nomeadas identificadas pelo NER funcionam como **âncoras semânticas**: pontos do texto que se referem a objetos, pessoas, organizações ou locais do mundo real.

Entretanto, **entidades isoladas não carregam significado suficiente** para caracterizar o conteúdo informacional de um texto.

Considere a saída de um sistema de NER:

- ORGANIZAÇÃO: Petrobras
- LOCAL: Santos

Sem contexto adicional, esses rótulos apenas indicam que duas entidades aparecem no texto. O significado emerge somente quando somos capazes de responder à pergunta:

Qual é a relação semântica entre essas entidades?

É exatamente nesse ponto que a análise semântica ultrapassa a identificação de referentes e passa a **modelar afirmações sobre o mundo**.

✂ Extração de Relações: do “quem” para o “o quê”

A Extração de Relações (Relation Extraction – RE) tem como objetivo identificar **vínculos semânticos estáveis** entre entidades previamente reconhecidas.

Exemplo:

“A Petrobras anunciou a exploração em Santos.”

Após o NER, sabemos que:

- “Petrobras” é uma ORGANIZAÇÃO;
- “Santos” é um LOCAL.

A extração de relação permite inferir algo semanticamente mais forte:

local_de_operação (Petrobras, Santos)

Do ponto de vista semântico, uma relação é composta por:

- **argumentos** (as entidades);
- **um predicado implícito ou explícito**, que expressa o tipo de vínculo entre elas.

Esse predicado não precisa aparecer literalmente no texto. Ele é uma **abstração semântica**, construída a partir do verbo, do contexto e do conhecimento estatístico do modelo.

No notebook, esse processo aparece quando utilizamos:

- dependências sintáticas como pistas;
- embeddings contextuais para classificar o tipo de relação.

♣ Da árvore sintática ao vínculo semântico

A extração de relações se apoia, mas não se limita, à sintaxe.

Na Aula 4, aprendemos a interpretar **árvores de dependência**, nas quais o verbo atua como núcleo da estrutura frasal. Na análise semântica, reutilizamos essa informação de forma estratégica:

- entidades próximas na árvore sintática tendem a estar semanticamente relacionadas;
- caminhos curtos entre nós indicam maior probabilidade de vínculo conceitual.

Contudo, a relação semântica **não é a própria dependência sintática**.

Exemplo:

“A empresa que adquiriu a fábrica anunciou novos investimentos.”

Sintaticamente, a relação entre “empresa” e “fábrica” é indireta e mediada por uma oração relativa.

Semanticamente, a relação de **posse** continua válida.

Modelos baseados em Transformers conseguem capturar esse tipo de relação porque a **atenção contextual** não está limitada à linearidade da frase nem à hierarquia sintática estrita.

Quando a relação não basta: a noção de evento **SLIDE 12**

Embora a extração de relações seja poderosa, ela ainda é limitada a estruturas **binárias**. Muitos fenômenos do mundo real não podem ser descritos adequadamente por uma simples relação entre duas entidades.

Considere:

“A empresa X comprou a empresa Y por 5 bilhões de reais em 2023.”

Aqui, temos algo mais complexo que uma relação. Temos um **evento**.

A Extração de Eventos busca capturar estruturas semânticas mais ricas, compostas por:

- **Gatilho (trigger)**: o termo que indica a ocorrência do evento
(ex.: “comprou”)
- **Participantes (arguments)**: entidades envolvidas
(comprador, vendedor)
- **Papéis semânticos**: função de cada entidade no evento
(agente, paciente, beneficiário)
- **Atributos circunstanciais**:
(tempo, local, valor, instrumento)

Um evento, portanto, representa a **semântica em quatro dimensões**: quem, o quê, quando e onde.

Eventos como estruturas centrais do significado

Do ponto de vista cognitivo e computacional, eventos são fundamentais porque:

- organizam a informação narrativa;
- permitem entender a ordem dos acontecimentos e as relações de causa e efeito;
- servem como base para raciocínio automatizado.

No notebook, mesmo quando não implementamos um sistema completo de extração de eventos, já damos os primeiros passos ao:

- identificar verbos gatilho;
- associar entidades a papéis implícitos;
- inferir tipos de ação a partir do contexto.

É importante compreender que **relações podem ser vistas como projeções simplificadas de eventos**. Um evento de “aquisição”, por exemplo, gera múltiplas relações: posse, controle, localização, valor.

Da extração de informação à descoberta de conhecimento **SLIDE 13**

Ao integrar:

1. Reconhecimento de Entidades (NER),
2. Extração de Relações,
3. Extração de Eventos,

atingimos o objetivo maior da análise semântica aplicada ao PLN: a Descoberta de Conhecimento em Textos (KDT). O texto deixa de ser apenas uma sequência linear de palavras e passa a ser representado como um conjunto de **estruturas lógicas**, frequentemente expressas como:

Sujeito – Predicado – Objeto

Essas triplas são a base dos Grafos de Conhecimento, que permitem:

- integração de múltiplos documentos;
- inferência automática; (sistema **consegue tirar conclusões sozinho a partir das informações que ele já tem**)
- resposta a perguntas complexas.

Nesse ponto, a linguagem natural deixa de ser apenas “interpretada” e passa a ser **operacionalizada como conhecimento**.

Conexão direta com a prática do notebook

O notebook da Aula 6 materializa esse capítulo ao propor um pipeline simplificado, no qual o sistema:

1. Identifica entidades relevantes (NER);
2. Localiza o verbo que as conecta (informação sintática);
3. Classifica semanticamente essa conexão;
4. Gera uma representação estruturada do fato descrito.

O objetivo pedagógico não é construir um sistema industrial completo, mas permitir que o aluno observe claramente a transição:

da frase → para a estrutura → para o significado → para o conhecimento