

# PLN

## Processamento de Linguagem Natural



# Aula 3 de **PLN**

Processamento de Linguagem Natural

## AULA 6 - ROTEIRO

- 1. O salto do “como” para o “o quê”
- 2. Reconhecimento de Entidades Nomeadas (NER)
- 3. Extração de Relações e Eventos
- 4. Pipeline semântico e descoberta de conhecimento

# Sintaxe não é Semântica

- A sintaxe descreve a estrutura do texto
- A semântica busca explicar o que o texto diz sobre o mundo
- Uma frase pode ser sintaticamente correta e semanticamente absurda
- O exemplo clássico de Noam Chomsky ilustra esse problema “Ideias verdes incolores dormem furiosamente.”
- Conclusão: forma correta  $\neq$  compreensão real
- A **sintaxe** descreve a estrutura do texto; a **semântica** tenta explicar o que o texto diz sobre o mundo

# O Problema da referência: palavras não são coisas

- Palavras não são coisas: elas apontam para objetos, conceitos, eventos ou entidades
- Exemplo: “Apple”
  - “Apple lançou um novo produto.” → empresa
  - “Apple é rica em fibras.” → fruta
- Sem resolver a referência, o sistema manipula símbolos
- Ao resolver a referência, o sistema extrai fatos
- **Reconhecimento de Entidades Nomeadas (NER)**



# Triângulo Semântico no PLN

- **Símbolo:** palavra ou sequência de tokens no texto
- **Conceito:** representação interna aprendida pelo modelo (embeddings)
- **Referente:** entidade/objeto no mundo real
- Transformers aproximam símbolo + contexto
- NER e etapas seguintes tentam ancorar essa interpretação ao mundo
- LOC (localização), ORG (organização) ou PER (pessoa),

## Por que a Semântica é Mais Complexa?

- A sintaxe olha a estrutura; a semântica exige conhecimento de mundo
- Exemplo: “O banco foi assaltado.” vs “O banco foi pintado de azul.”
- A palavra é a mesma, mas o sentido depende do contexto
- Modelos aprendem isso estatisticamente a partir de grandes volumes de dados
- Erros semânticos afetam todo o pipeline

# Reconhecimento de Entidades Nomeadas

- **NER** identifica trechos do texto que se referem a entidades do mundo real

Enquanto a **sintaxe** responde à pergunta:

*“Qual é a função gramatical desta palavra?”*

o **NER** responde a uma pergunta qualitativamente diferente:

*“Este trecho do texto se refere a uma entidade específica do mundo?”*

- Categorias comuns: PER, ORG, LOC, DATE, TIME, MONEY
- NER é uma decisão semântica, não apenas lexical
- Exemplo: “Amazon anunciou investimentos.” → ORG, não rio



# Taxonomias e BIO Tagging

- Taxonomias: conjuntos finitos de rótulos semânticos

São mais simples que ontologias, mas computacionalmente viáveis

- BIO = Beginning, Inside, Outside
- Permite reconhecer entidades com múltiplos tokens
- Exemplo: B-ORG Fatec | I-ORG de |  
I-ORG Jacareí | O anunciou

# Desafios do NER: Ambiguidade Semântica

- **Polissemia**: mesma expressão, entidades diferentes conforme o contexto
  - “O Rio de Janeiro continua lindo.” → Local
  - “O Rio de Janeiro aprovou a nova lei.” → Governo/entidade política
- **Metonímia**: um local representa uma instituição ou grupo humano
  - “Brasília decidiu aumentar os impostos.”
- Transformers lidam melhor com isso por causa da atenção contextual

# Extração de Relações

- Entidades isoladas não produzem conhecimento suficiente
- A Extração de Relações identifica vínculos semânticos entre entidades
- Exemplo: “A Petrobras anunciou a exploração em Santos.”
  - Petrobras = ORG | Santos = LOC
  - Relação inferida: local\_de\_operação (Petrobras, Santos)
- Do ponto de vista semântico, uma relação é composta por:
- **argumentos** (as entidades);
- **um predicado implícito ou explícito,**

# Extração de Eventos

- Nem tudo cabe em relações binárias: muitos fatos são eventos
- Exemplo: “A empresa X comprou a empresa Y por 5 bilhões em 2023.”
- Elementos do evento:
  - Gatilho (**trigger**): “comprou”
  - Participantes (**arguments**): comprador e vendedor
  - Papéis semânticos: agente, paciente, etc.
  - Atributos: tempo, local, valor
- Eventos capturam **quem, o quê, quando e onde**

# Pipeline Semântico e KDT

- Pipeline simplificado:
  - 1. NER → identificar entidades
  - 2. Relações → conectar entidades
  - 3. Eventos → estruturar fatos complexos
- Resultado: frase → estrutura → significado → conhecimento
- Base para triplas semânticas (Sujeito – Predicado – Objeto)
- Essas triplas alimentam Grafos de Conhecimento e KDT

## Resumo da Aula

- Sintaxe organiza a frase; semântica interpreta o mundo
- NER é a base para relações e eventos
- Erros semânticos têm alto impacto em aplicações reais
- A integração dessas etapas permite descoberta de conhecimento em textos
- Próximo passo sugerido: atividade prática com notebook de NER + relações